UPSSA
UNIVERSITÉ PRIVÉE DE LA SANTÉ ET DES SCIENCES D'AGADIR
الجامعة الخاصة للصحة و العلوم لأكادير
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵜⵉⵖⵓⵔⵉⵜ ⵏ ⵜⵎⴰⵡⴰⵙ ⴷ ⵜⵎⴰⵡⵉⵜ ⵏ ⵜⵎⴰⵡⴰⵙ ⵏ ⵜⵎⵙⵓⵙⵙⴰ

ÉCOLE SUPÉRIEURE PRIVÉE D'INGÉNIERIE D'AGADIR
المدرسة العليا الخاصة للهندسة بأكادير
ⵜⵉⵎⵙⵙⵓⵔⵉⵏ ⵜⵉⵖⵓⵔⵉⵏ ⵏ ⵜⵎⵙⵓⵙⵙⴰ ⵏ ⵜⵎⵙⵓⵙⵙⴰ ⵏ ⵜⵎⵙⵓⵙⵙⴰ

COURS

CONCEPTION DES BASES DE DONNÉES

Par

Pr. Ayoub TAMIM

2026 - 2027

Sommaire

Introduction aux systèmes d'information

1. Introduction
   1.1 Données et Informations
   1.2 Définition d'une Information
   1.3 Définition d'un système
   1.4 Définition d'un système d'information
2. Le concept de système d'information
   2.1 Opérant
   2.2 Système de pilotage
   2.3 Système d'information
   2.4 Exemple de concept de système d'information
3. Fonction d'un système d'information
   3.1 La saisie
   3.2 Le stockage
   3.3 Le traitement
   3.4 La restitution
   3.5 Transmission et communication
4. Les systèmes d'information et les fonctions de l'entreprise
   4.1 Comptabilité et Gestion des stocks
   4.2 L'informatique bureautique
   4.3 Ventes et Marketing
   4.4 Bureau d'étude (Ingénierie)
   4.5 Production et fabrication
   4.6 Logistique et relation client-fournisseur
   4.7 Management et direction

Les SI et les fonctions de l'entreprise (Résumé)

Introduction au système MERISE

1 Modèle conceptuel de données (MCD)

1.1 Schéma entités-associations
   1.1.1 Entités et associations
   1.1.2 Attributs et identifiants
   1.1.3 Cardinalités
   1.1.4 Associations plurielles
   1.1.5 Association réflexive
   1.1.6 Associations non binaires
1.2 Règles de normalisation
   1.2.1 Les bonnes manières dans un schéma entités-associations
   1.2.2 Les formes normales

1.3 Dépendances fonctionnelles
1.3.1 Définitions et propriétés
1.3.2 Graphe de couverture minimale
1.3.3 Traduction vers un schéma entités-associations
1.3.4 Gestion des dates et du caractère historique
1.3.5 Dépendances plurielles et réflexives
1.3.6 Associations sans attributs
1.4 Méthodologie de base
2 Modèle logique de données (MLD)
2.1 Systèmes logiques
2.2 Modèle logique relationnel
2.2.1 Tables, lignes et colonnes
2.2.2 Clés primaires et clés étrangères
2.2.3 Schéma relationnel
2.3 Traduction d'un MCD en un MLDR
3 Modèle physique de données (MPD)
3.1 Distinction entre MLD et MPD
3.2 Optimisations

Introduction aux systèmes d'information

1. Introduction

Toute organisation produit et utilise des informations : commandes, factures, résultats d'examens, données de stock ou dossiers du personnel. Ces informations accompagnent les activités quotidiennes et permettent aux responsables de prendre des décisions. Leur utilité dépend de la manière dont elles sont recueillies, organisées, conservées et communiquées.

Le système d'information coordonne ces opérations. Son étude précède la conception des bases de données : avant de créer des tables, il faut comprendre les acteurs, les activités, les échanges et les règles de fonctionnement de l'organisation.

À l'issue de ce chapitre, l'étudiant doit pouvoir distinguer une donnée d'une information, définir un système d'information, reconnaître les systèmes opérant et de pilotage, identifier les principaux flux et expliquer les fonctions du SI dans l'entreprise. Ces acquis serviront ensuite à la modélisation avec la méthode Merise.

1.1 Données et Informations

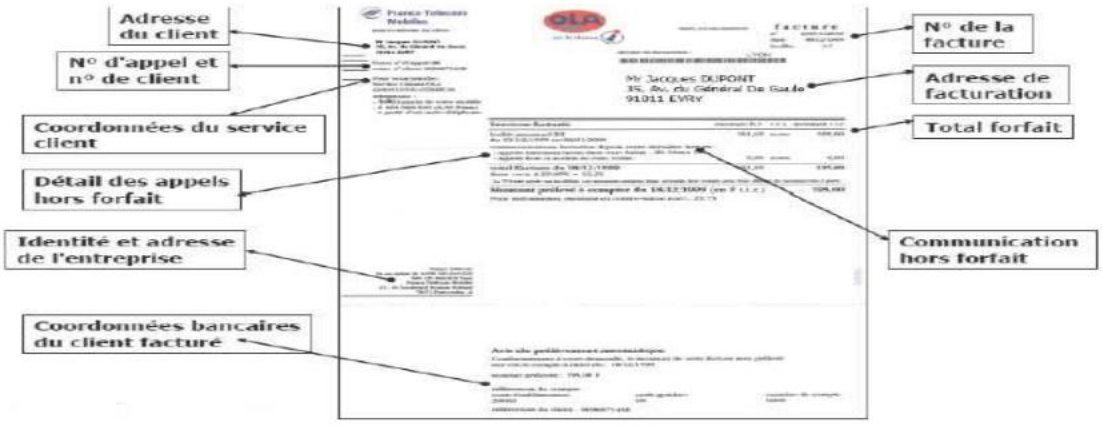
Une donnée est une représentation codée d'un fait, d'une mesure ou d'un événement. Elle peut prendre la forme d'un nombre, d'un texte, d'une date, d'une image ou d'un son. Pour l'interpréter, il faut connaître le code employé et le contexte dans lequel elle a été produite.

Une information est le sens que l'on attribue à une donnée dans un contexte donné. Ainsi, la valeur « 38 » peut désigner un âge, une quantité en stock ou une température. La précision « température mesurée en degrés Celsius » permet de comprendre la mesure.

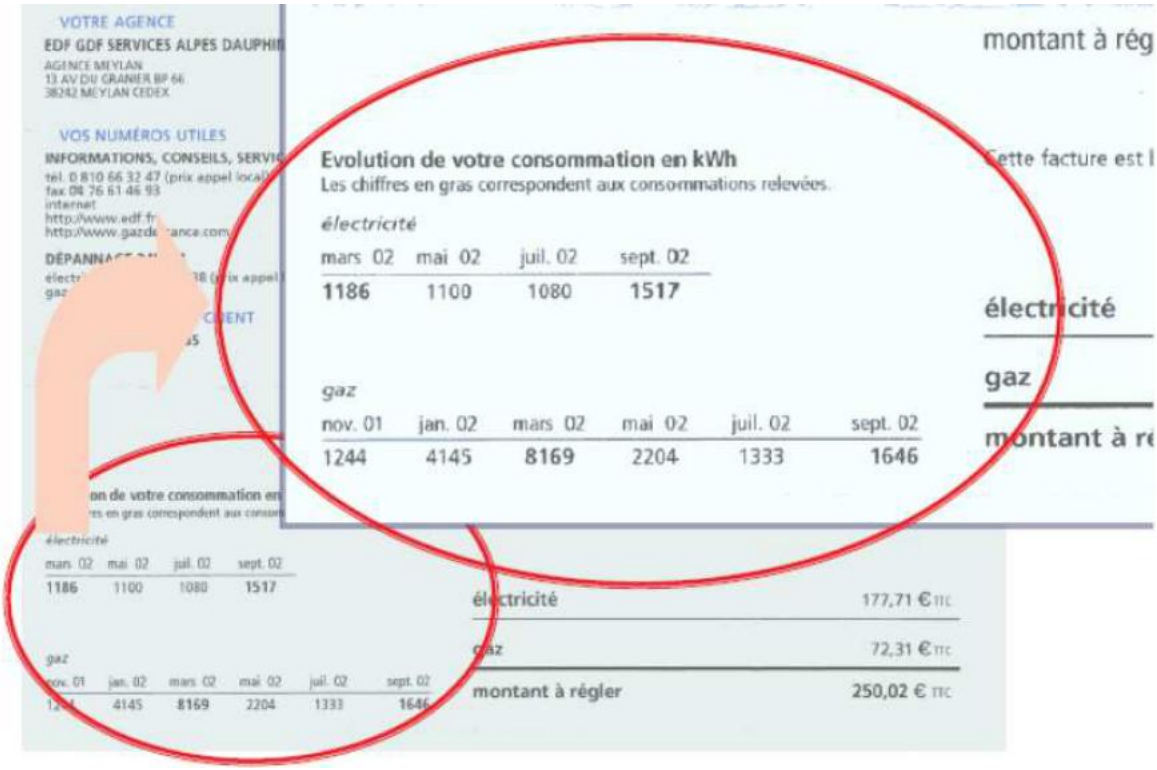
On peut retenir les relations pédagogiques suivantes : donnée = signes interprétés selon un code ; information = donnée replacée dans son contexte.

Les dates illustrent cette dépendance au contexte. La notation 03/04/2026 désigne le 3 avril selon la convention jour/mois/année, mais le 4 mars selon la convention mois/jour/année. Le format doit donc être explicité pour éviter les erreurs.

Exemples de lecture et d'interprétation de factures



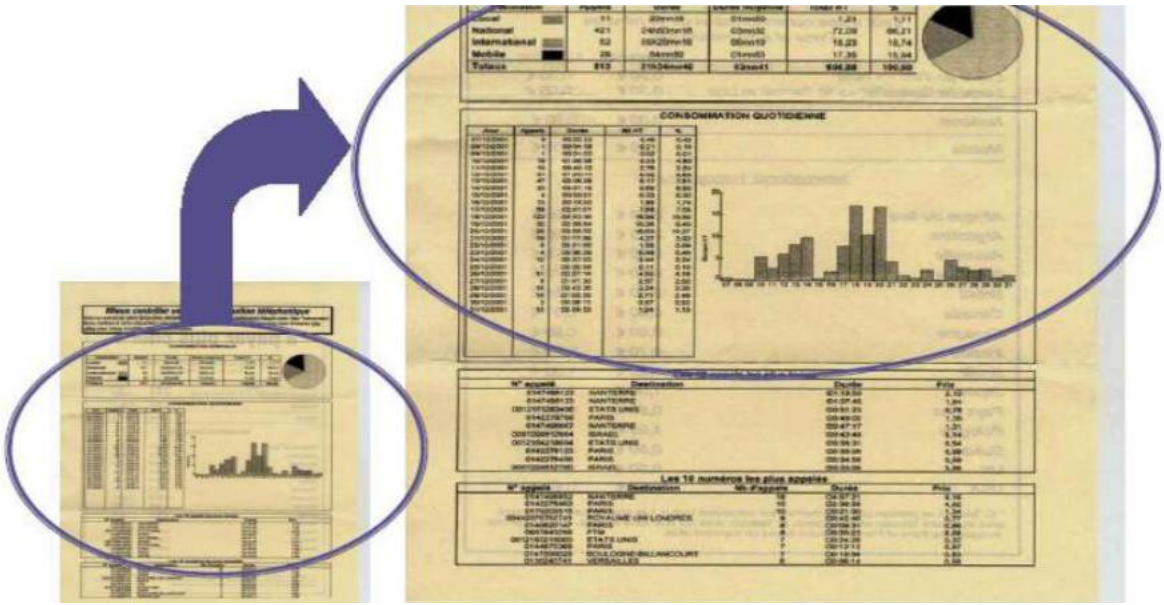
Une facture associe des données à des libellés et à des unités : numéro du client, période concernée, consommation, prix unitaire et montant à payer. Ces indications constituent le cadre nécessaire à son interprétation. Un montant isolé ne permet pas de savoir s'il représente un prix hors taxes, une taxe ou le total à régler.



La deuxième facture complète les données de la période par un historique des consommations. Le client peut comparer plusieurs périodes, repérer une variation et adapter ses usages. Les mêmes données servent ainsi à la facturation et à une analyse simple de l'évolution de la consommation.

La valeur de l'information ne réside donc pas seulement dans les chiffres fournis. Elle dépend également de leur sélection, de leur présentation et de leur adéquation au besoin du destinataire.

Le troisième exemple ajoute des graphiques et des courbes. Cette représentation rend les évolutions plus visibles, à condition de préciser les périodes, les unités et les échelles. Le système d'information transforme ici des enregistrements détaillés en une présentation qui facilite la compréhension.



Les évolutions de l'activité doivent être accompagnées par celles du système d'information. Une nouvelle offre commerciale, une modification du processus de fabrication ou l'ouverture d'un service peut nécessiter de nouvelles données, de nouveaux traitements et de nouveaux

échanges. La conception du SI doit donc tenir compte du fonctionnement de l'organisation et de ses objectifs.

1.2 Définition d'une Information

Une information est un élément de connaissance qui peut être représenté, conservé, traité et communiqué. Pour un destinataire donné, elle permet de comprendre une situation, de réduire une incertitude ou de préparer une action.

Une donnée n'est pas utile de la même manière à tous les acteurs. Le magasinier recherche la quantité disponible d'un article ; le responsable des achats étudie plutôt les besoins à venir et les délais des fournisseurs. La pertinence dépend du rôle de l'utilisateur et de la décision à prendre.

Exemple : dans une bibliothèque, un étudiant cherche un ouvrage complet sur la théorie de l'information. Le domaine, le type de document et le niveau du contenu réduisent progressivement le nombre de références à consulter. Chaque précision pertinente diminue l'incertitude et oriente la recherche.

Les informations peuvent être classées selon plusieurs critères complémentaires.

Selon leur origine, les informations internes sont produites par l'organisation, comme les ventes enregistrées ou les quantités fabriquées. Les informations externes proviennent de son environnement, comme les tarifs des fournisseurs ou les demandes des clients.

Selon leur durée d'utilité, certaines informations sont temporaires, comme l'état instantané d'une file d'attente. D'autres doivent être conservées pour constituer une mémoire, permettre des comparaisons ou justifier une opération : factures, contrats et historiques de commandes. Leur durée de conservation dépend du besoin et des règles applicables.

Selon les traitements réalisés, on distingue les données brutes, comme une quantité mesurée, et les informations calculées, comme un total de ventes ou un salaire obtenu à partir de plusieurs éléments. Une information calculée doit pouvoir être reliée aux données et aux règles utilisées pour la produire.

1.3 Définition d'un système

Un système est un ensemble d'éléments organisés qui interagissent pour atteindre une finalité. Il possède une frontière, échange avec son environnement et transforme des entrées en sorties au moyen d'activités ou de traitements.

Dans une entreprise de fabrication, les matières premières constituent des entrées, les opérations de production réalisent la transformation et les produits finis constituent des sorties. Des ressources humaines, matérielles et financières rendent ce fonctionnement possible.

Cette approche s'applique également aux services. Dans un établissement d'enseignement, les inscriptions, les enseignements et les évaluations forment un ensemble d'activités coordonnées qui contribuent à la formation des étudiants.

1.4 Définition d'un système d'information

Un système d'information est un ensemble organisé de personnes, de données, de procédures et de moyens techniques permettant de recueillir, mémoriser, traiter et diffuser l'information nécessaire à une organisation.

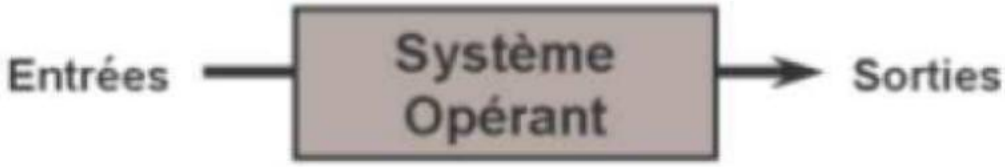
Il ne se réduit pas aux ordinateurs et aux logiciels. Un formulaire papier, une consigne de validation et le travail d'un agent participent également au SI. Le système informatique représente la partie automatisée de cet ensemble.

Le SI doit fournir aux bons acteurs une information compréhensible, fiable et disponible au moment où elle est nécessaire. Il soutient à la fois l'exécution des activités et leur pilotage.

2. Le concept de système d'information

2.1 Opérant

La représentation systémique distingue les activités réalisées, les décisions prises et les informations échangées.

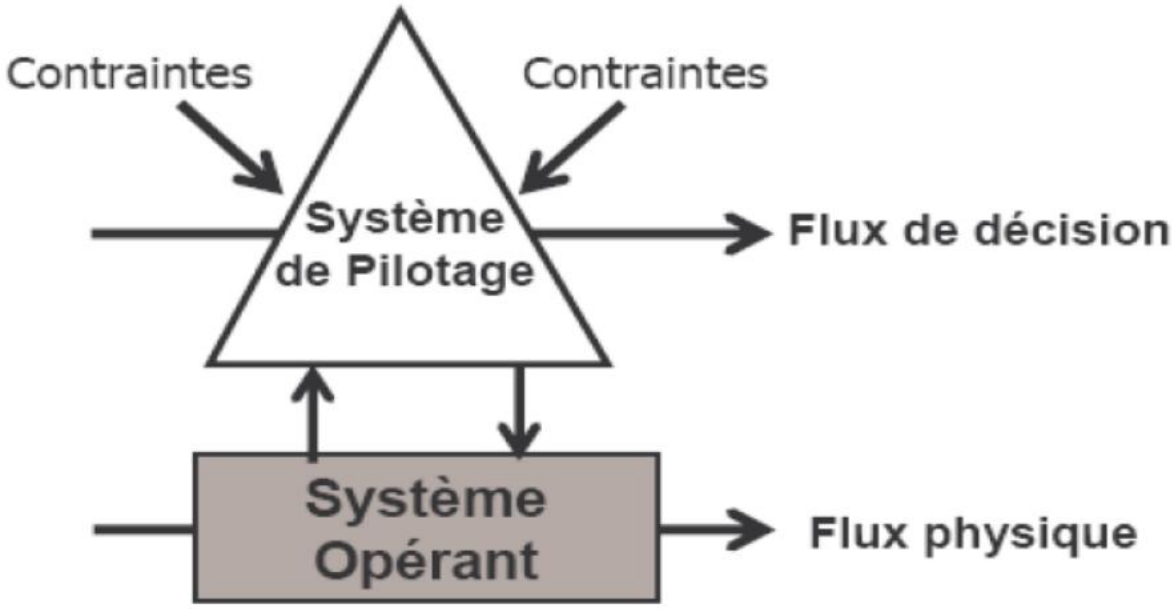


Le système opérant réalise les activités qui constituent la mission de l'organisation. Il transforme des ressources en biens ou en services : fabriquer un produit, préparer une commande, assurer une consultation ou dispenser un enseignement.

Dans une école, il comprend notamment l'accueil des étudiants, l'organisation des cours, la réalisation des évaluations et la gestion matérielle des séances. Les enseignants, les étudiants et les services concernés y participent selon leurs responsabilités.

Les flux physiques ou opérationnels correspondent aux mouvements et aux opérations de l'activité. Les inscriptions, notes et résultats sont les représentations informationnelles de certains de ces événements. Il convient donc de distinguer l'activité elle-même des données qui la décrivent.

2.2 Système de pilotage



Le système de pilotage fixe les objectifs, observe les résultats et décide des actions à mener. Il

compare la situation constatée à la situation attendue, puis ajuste les ressources, les priorités ou les règles de fonctionnement.

Il s'appuie sur des informations de suivi : volumes d'activité, coûts, délais, taux de réussite ou écarts par rapport aux prévisions. Les décisions qu'il produit sont transmises au système opérant sous forme de consignes, de budgets ou de plans d'action.

Dans un établissement d'enseignement, le pilotage peut concerner les capacités d'accueil, la répartition des moyens, l'organisation des formations ou les investissements matériels. Ces choix prennent en compte les objectifs de l'établissement et les contraintes de son environnement.

2.3 Système d'information

Le système d'information relie le système opérant au système de pilotage. Il enregistre les événements de l'activité, les conserve, réalise les traitements nécessaires et transmet les résultats aux acteurs concernés.

Pour les activités quotidiennes, il fournit des informations détaillées et directement exploitables : disponibilité d'un article, état d'une commande ou liste des étudiants inscrits à un examen. Pour le pilotage, il produit des informations de synthèse : évolution des ventes, délais moyens ou taux de réussite.

La même donnée peut donc alimenter plusieurs usages. Une vente enregistrée sert à établir une facture, à mettre à jour le stock et à calculer le chiffre d'affaires. La cohérence de ces usages dépend de la qualité des données et des règles de traitement.

Le SI construit une représentation de l'organisation. Cette représentation sélectionne les éléments utiles à ses missions : acteurs, objets gérés, événements et relations entre ces éléments. Elle ne reproduit pas toute la réalité.

Dans le dossier pédagogique d'un étudiant, l'identifiant, les inscriptions, les notes et les résultats sont utiles à la scolarité. Les informations sans rapport avec cette finalité n'ont pas à être ajoutées. La pertinence d'une donnée doit toujours être appréciée en fonction du besoin auquel elle répond.

La conception du SI consiste à définir cette représentation et les règles qui organisent son fonctionnement. Un modèle cohérent facilite le partage de l'information, limite les contradictions et prépare la construction d'une base de données adaptée.

Le SI mobilise des moyens humains, organisationnels et techniques. Certaines activités, comme l'hébergement ou la maintenance des applications, peuvent être confiées à un prestataire : on parle alors d'externalisation ou d'infogérance. Ce choix nécessite de préciser les responsabilités, les services attendus et les conditions de continuité de l'activité.

2.4 Exemple de concept de système d'information

Premier exemple : un établissement d'enseignement. Les activités opérationnelles comprennent l'accueil des étudiants, les cours, les examens et la délivrance des résultats. Les données associées décrivent les étudiants, les formations, les inscriptions, les évaluations et les ressources mobilisées.

Le flux d'information transmet notamment les listes d'inscription, les emplois du temps, les notes et les bilans de réussite. Le flux de décision porte sur les capacités d'accueil, les

programmes, l'affectation des moyens et l'organisation des évaluations.

Deuxième exemple : une entreprise ferroviaire. Les déplacements des trains et des voyageurs relèvent des flux physiques. Les réservations, les horaires et les états de circulation relèvent des flux d'information. L'affectation des moyens ou l'adaptation de l'offre relève du pilotage. Le schéma suivant illustre ces échanges.

Flux physique

- *Les trains, les wagons, les voyageurs, les billets, les réservations, les départs et les arrivés, les trajets (par exemple : Paris - Lyon), le paiement d'un billet, … etc.*

Flux d'information

- *Le trajet (n° de trajet, nom ville départ et nom ville d'arrivée, fréquence, heure départ et arrivée), n° de billet, n° de réservation, n° siège réservé, heure effective d'un départ et heure effective d'une arrivée, … etc.*
- *Des informations plus synthétiques tels que la répartition du nombre de voyageurs sur un trajet selon les périodes de l'année, la répartition des voyageurs selon les trajets pendant les périodes de Noël des 5 dernières années, la répartition du CA (chiffre d'affaire) d'un trajet selon les jours de la semaine pour les 3 derniers mois, … etc.*

Flux de décision

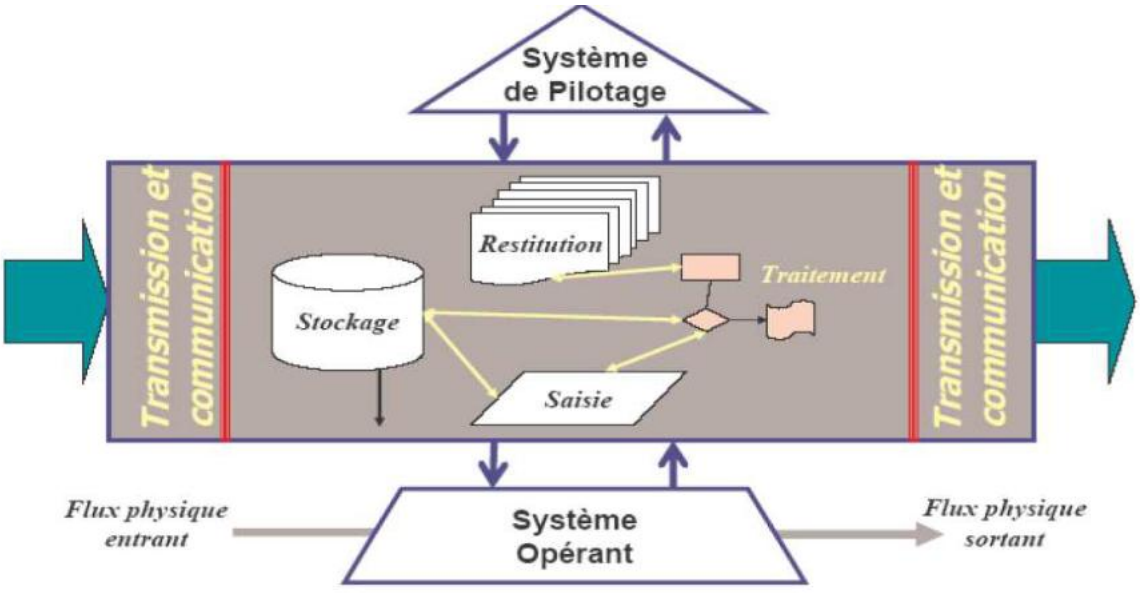
- *Définition de la grille tarifaire, définition des trajet pour une période donnée, ouverture de nouveaux trajets (par exemple : un Paris-Berlin hebdomadaire le Vendredi soir à 22h), la fermeture de certains trajets, l'achat de nouveaux équipement, … etc.*

Contraintes

- *La réglementation, les cycles économiques, l'inflation, les syndicats, … etc.*

3. Fonction d'un système d'information

Le fonctionnement d'un système d'information repose sur cinq fonctions complémentaires : la saisie, le stockage, le traitement, la restitution et la communication. Elles interviennent dans les activités quotidiennes comme dans l'aide à la décision. Le schéma suivant présente leur articulation.



3.1 La saisie

La saisie consiste à recueillir et enregistrer les données à leur source. Elle peut être manuelle, au moyen d'un formulaire, ou automatisée, par lecture d'un code-barres, acquisition d'un capteur ou import d'un fichier.

Les contrôles de saisie vérifient notamment la présence des informations obligatoires, leur format et leur cohérence. Par exemple, une quantité commandée doit respecter les règles de

gestion retenues. Une erreur à l'entrée risque de se propager dans tous les traitements ultérieurs.

3.2 Le stockage

Le stockage permet de conserver les données afin de les retrouver, de les partager et de les réutiliser. Il peut s'appuyer sur des fichiers, des bases de données et des supports d'archivage.

Une organisation du stockage doit préciser les données conservées, leurs relations, les droits d'accès et les modalités de sauvegarde. Les données courantes servent au fonctionnement quotidien ; les historiques permettent de retracer les opérations et d'étudier les évolutions. Une sauvegarde protège contre la perte de données, tandis que l'archivage répond à un besoin de conservation dans la durée.

3.3 Le traitement

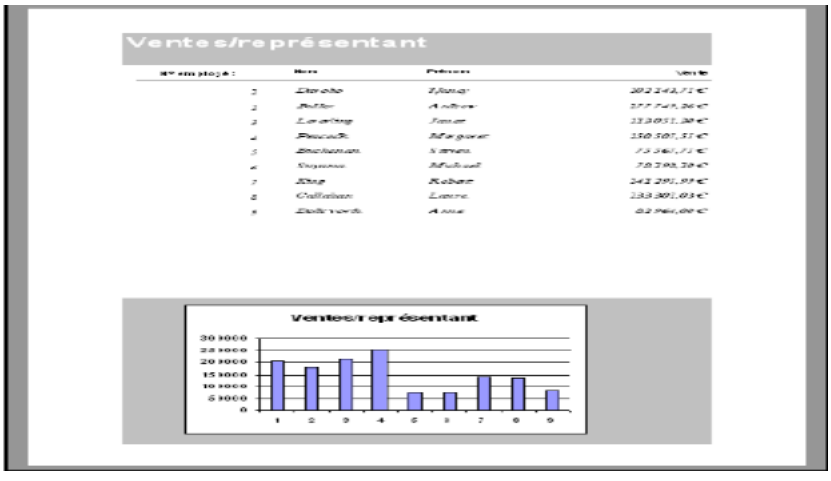
Le traitement transforme des données en résultats utiles. Il comprend les calculs, les tris, les regroupements, les recherches, les comparaisons et l'application de règles de gestion.

Par exemple, le montant d'une ligne de commande est obtenu à partir d'une quantité et d'un prix unitaire. Le regroupement des ventes par période permet ensuite de calculer des totaux et de comparer les résultats.

Un traitement doit être défini par ses données d'entrée, les règles appliquées et les résultats attendus. Il peut être effectué immédiatement lors d'une opération ou à intervalles réguliers, selon les besoins.

3.4 La restitution

La restitution présente les résultats aux utilisateurs sous une forme adaptée : écran de consultation, facture, relevé, tableau de bord, rapport ou document imprimé. Elle rend l'information exploitable sans obliger le destinataire à examiner tous les enregistrements de départ.



La présentation dépend du public et de l'usage. Un agent de scolarité consulte une liste détaillée pour vérifier une inscription ; un responsable pédagogique utilise une synthèse des effectifs et des résultats. Les titres, unités, périodes et critères de calcul doivent être explicites.

Le choix du support, papier ou numérique, ne suffit pas à garantir la qualité de la restitution. Il faut également veiller à la lisibilité, à l'exactitude et à la mise à jour des informations présentées.

3.5 Transmission et communication

La communication assure la circulation de l'information entre personnes, services et organisations. Elle peut prendre la forme d'un échange de documents, d'une messagerie, d'un accès à une application partagée ou d'un transfert automatisé de données.

Les échanges numériques utilisent des réseaux et des protocoles de communication. Leur organisation doit préciser l'émetteur, le destinataire, le contenu, le moment de l'envoi et les conditions d'accès. Un transfert techniquement réussi ne garantit pas, à lui seul, que l'information soit comprise et utilisée correctement.

4. Les systèmes d'information et les fonctions de l'entreprise

Les besoins d'information varient selon les fonctions de l'entreprise. La comptabilité suit les opérations financières ; la production organise les ressources et les fabrications ; les ventes gèrent les offres et les commandes ; les ressources humaines suivent le personnel ; la direction analyse l'activité et prépare les décisions.

Ces fonctions partagent souvent les mêmes données. Une commande client intéresse les ventes, le magasin, la logistique et la comptabilité. La coordination du SI permet de transmettre des informations cohérentes entre ces services et de limiter les ressaisies.

4.1 Comptabilité et Gestion des stocks

La comptabilité enregistre les opérations qui affectent la situation financière de l'entreprise. Elle exploite notamment les factures, les règlements et les mouvements comptables pour établir des états de suivi et de synthèse.

La gestion des stocks suit les entrées, les sorties et les quantités disponibles. Elle aide à préparer les réapprovisionnements et à limiter les ruptures ou les excédents. Le rapprochement des commandes, des livraisons et des factures nécessite des données cohérentes entre les services.

Comptabilité et gestion des stocks

C'est la principales porte d'entrée de l'informatique dans l'entreprise.

Les fonctions comptables sont les premières à être automatisées :

- Calcul et édition des fiches de paie.
- Suivi des achats, des livraisons, des ventes.
- Calcul et édition des factures.
- Etats comptables et gestion financière.



Connecticut Mutual Life Insurance : Un entrepôt de la taille d'un stade de football !

L'illustration évoque également la gestion documentaire. Dans une entreprise d'assurance, les dossiers clients peuvent réunir contrats, déclarations, justificatifs et demandes de remboursement. Leur organisation doit permettre aux agents autorisés de retrouver les pièces utiles et de suivre l'état d'un dossier.

L'informatisation facilite la recherche et le partage, mais elle exige des règles de classement, de validation et d'accès. La numérisation d'un document ne remplace donc pas l'organisation de son cycle de traitement.

4.2 L'informatique bureautique

Elle remplit 3 tâches essentielles :

- Le secrétariat et la production de l'écrit, grâce au logiciels de traitement de texte, aux tableurs, et autres logiciels "Office".
- L'organisation et la gestion des informations locales à un individu.
- La communication grâce principalement à la messagerie électronique, mais aussi le groupware et le travail en groupe.

La bureautique soutient la production et la circulation des documents : traitement de texte, tableur, présentations, messagerie, agendas et espaces de travail partagés. Ces outils facilitent la rédaction, les calculs simples et la coordination des activités.

Leur utilisation doit rester cohérente avec le SI. Des fichiers indépendants et des copies multiples peuvent entraîner des versions contradictoires. Les utilisateurs doivent pouvoir identifier les documents de référence et les règles de mise à jour.

4.3 Ventes et Marketing

Pour un vendeur, il est indispensable de bien connaître :

- les produits, leurs prix et ses possibilités de manœuvre;
- la disponibilité des produits;
- le profil du client : volume d'achat, habitudes de consommation, préférences, ...

Etude de cas

Près de Grenoble, une usine de grenaille de fer fournit plus de 8000 entreprises réparties dans 70 pays différents. Les commerciaux doivent connaître aussi bien la qualité des différentes grenailles que les machines des clients dans lesquelles elles seront utilisées. Résultat : 17000 fiches mises à jour annuellement par 70 vendeurs ... Elles sont traitées sur le mini-ordinateur (AS400 d'IBM) du siège de l'entreprise. La fiche de renseignement est mise au point par le service informatique. Elle comprend les noms et adresses des clients, leur consommation et secteurs d'activité, leurs équipements et leur mode d'utilisation de la grenaille.

Le SI commercial rassemble les informations utiles à la vente : clients, produits, tarifs, disponibilités, devis et commandes. Il permet de suivre les échanges avec les clients et d'évaluer les résultats commerciaux.

Un commercial en déplacement peut consulter une application pour vérifier un stock ou préparer une offre. Le marketing analyse les ventes et les retours des clients afin d'adapter les actions proposées. La qualité de ces analyses dépend de données correctement renseignées et mises à jour.

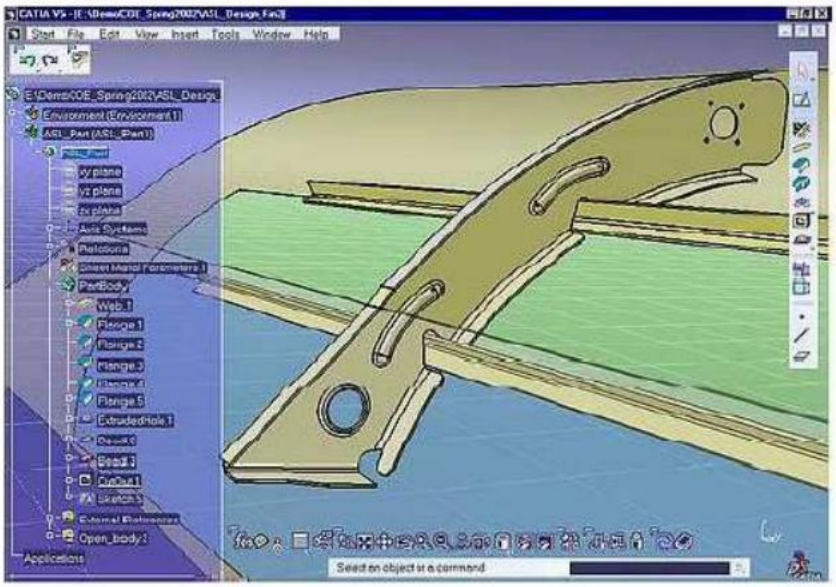
4.4 Bureau d'étude (Ingénierie)

Le bureau d'étude utilise le SI pour concevoir et documenter les produits : caractéristiques techniques, plans, maquettes et résultats de validation. Les outils de conception assistée par ordinateur facilitent la préparation des modèles. Le partage de versions identifiées évite qu'un atelier travaille à partir d'un plan périmé.

Exemple

Né des besoins précis du constructeur d'avions français, ce logiciel s'adresse dès le début des années 90 aussi bien aux industriels de l'automobile qu'aux architectes. Son premier client est IBM, son deuxième est Boeing ... C'est le logiciel de CAO le plus utilisé au monde par les industriels de l'aéronautique et de l'automobile. En 1990, il équipait plus de 1500 gros ordinateurs et près de 3000 stations de travail IBM !

Depuis, son concepteur a décidé d'en faire un plate-forme de développement pour fabriquer des logiciels plus spécialisés. Devenu un généraliste, CATIA sera utilisé aussi bien par les mécaniciens, les stylistes ou les architectes.



4.5 Production et fabrication

L'ordinateur dans l'atelier et dans l'usine pour :

- Baisser les prix de revient et augmenter la productivité en automatisant et en "robotisant" les tâches de production.
- Fabriquer le bon produit au bon moment.
- Fabriquer de produits en masse et à la demande (selon l'idée de "*mass customisation*").

Le SI de production aide à planifier les fabrications, à affecter les ressources et à suivre leur réalisation. Il met en relation les besoins issus des commandes, les stocks disponibles et les capacités de production.

Dans une fabrication personnalisée, les caractéristiques demandées par le client doivent être transmises sans ambiguïté aux équipes et aux équipements concernés. Le cas du vélo sur mesure illustre cette continuité : les mesures et les options sont enregistrées, utilisées pour définir le produit, puis transmises à la fabrication.

Le suivi de production permet ensuite de connaître l'avancement, de relever les contrôles réalisés et de préparer la livraison. La cohérence entre commande, conception, fabrication et expédition est donc essentielle.

4.6 Logistique et relation client-fournisseur

La logistique coordonne les approvisionnements, les mouvements de produits et les livraisons. Elle s'appuie sur les commandes, les disponibilités, les délais et les confirmations de réception pour organiser les opérations.

La gestion de la relation client, souvent désignée par CRM, rassemble les informations utiles au suivi commercial et au service après-vente. Elle permet de retrouver l'historique des échanges, de suivre les demandes et d'adapter les réponses au contexte du client.

Les échanges avec les fournisseurs peuvent être automatisés grâce à des formats partagés. L'échange de données informatisé, ou EDI, permet par exemple de transmettre des commandes, des avis d'expédition et des factures entre systèmes. Il réduit les ressaisies lorsque les

partenaires partagent les mêmes règles d'interprétation des données.

4.7 Management et direction

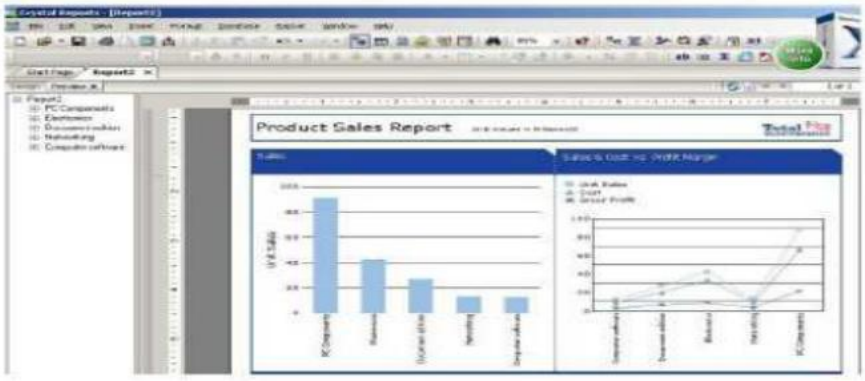
La direction utilise des tableaux de bord pour suivre les objectifs, analyser les résultats et comparer plusieurs scénarios. Les indicateurs doivent avoir une définition claire : mode de calcul, période étudiée, source et fréquence de mise à jour. Une synthèse utile met les résultats en perspective et aide à déterminer les actions à mener.

C'est le système d'information du "patron" :

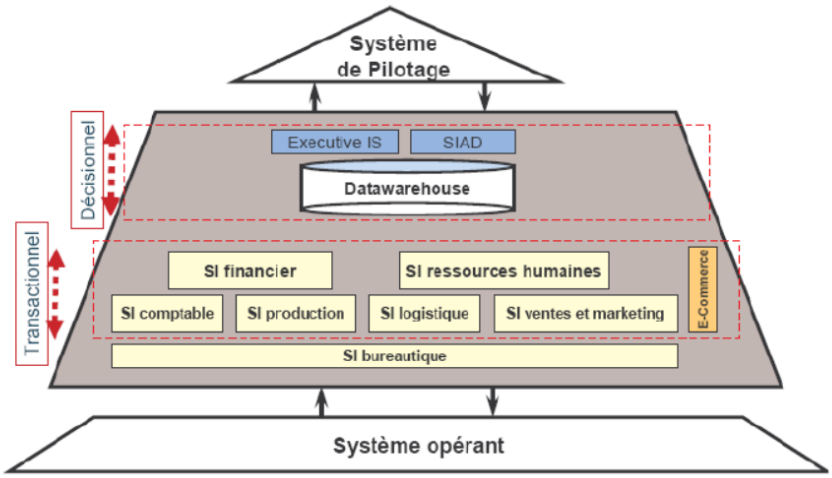
- Tableaux de bord basés sur des indicateurs clés.
- Objectif : Assister et faciliter la prise de décision.
- Diverses terminologies : EIS (*Executive Information System*), SIAD (Système *Interactif d'Aide à la Décision*), *SI stratégique*.

Exemple :

- *Business Objects*



Les SI et les fonctions de l'entreprise (Résumé)



La vision fonctionnelle du SI distingue deux usages complémentaires.

Le premier soutient les opérations quotidiennes. Les applications enregistrent les commandes, les paiements, les mouvements de stock ou les inscriptions. Elles manipulent des données détaillées et doivent permettre une mise à jour cohérente lors de chaque opération.

Le second soutient le pilotage. Il regroupe et compare les données pour produire des indicateurs, analyser les évolutions et préparer des décisions. Un responsable peut ainsi étudier les ventes par période, les délais moyens ou les écarts par rapport aux objectifs. Des entrepôts de données peuvent réunir des informations issues de plusieurs sources pour ces analyses.

Ces deux usages reposent sur des données fiables et des règles explicites. Le passage aux

chapitres suivants consiste à concevoir la structure de ces données : identifier les entités et leurs relations dans le MCD, les traduire en tables dans le MLD, puis préciser leur implantation dans le MPD.

Introduction

Quand nous construisons directement les tables d'une base de données dans un logiciel de gestion des bases de données (Oracle, SQL Server, DB2, Access, MySQL, PostGre, ...), nous sommes exposés à deux types de problème : – nous ne savons pas toujours dans quelle table placer certaines colonnes (par exemple, l'adresse de livraison se met dans la table des clients ou dans la table des commandes?) ; – nous avons du mal à prévoir les tables de jonction intermédiaires (par exemple, la table des interprétations qui est indispensable entre les tables des films et la table des acteurs). Il est donc nécessaire de recourir à une étape préliminaire de conception.

Les techniques présentées ici font partie de la méthodologie Merise (Méthode d'Étude et de Réalisation Informatique pour les Systèmes d'Entreprise) élaborée en France en 1978 [Tardieu et al.], qui permet notamment de concevoir un système d'information d'une façon standardisée et méthodique.

Ce cours présente le modèle conceptuel de données et les schémas entités-associations, puis le modèle logique relationnel et le modèle physique. Il explique la traduction du MCD vers le modèle relationnel et la construction du MCD à partir des dépendances fonctionnelles.

Ne sont malheureusement pas abordés ici : les contraintes, les traitements, le langage relationnel et la gestion de projet. Pour toutes ces notions importantes, car liées à la conception de systèmes d'information, le lecteur est dirigé vers [Akoka et Comyn-Wattiau, Matheron, Nanci et al.]. La modélisation objet ne fait pas non plus partie des outils exposés dans ce document.

1 Modèle conceptuel de données (MCD)

Avant de réfléchir au schéma relationnel d'une application, il est bon de modéliser la problématique à traiter d'un point de vue conceptuel et indépendamment du logiciel utilisé.

1.1 Schéma entités-associations

La modélisation conceptuelle que nous proposons dans ce document pour un univers dont on veut stocker les données, conduit à l'élaboration d'un type de schéma très répandu, le schéma entités-associations.

1.1.1 Entités et associations

Une entité est une population d'individus homogènes. Par exemple, les produits ou les articles vendus par une entreprise peuvent être regroupés dans une même entité articles (figure 1), car d'un article à l'autre, les informations ne changent pas de nature (à chaque fois, il s'agit de la désignation, du prix unitaire, etc.).



Fig. 1 – Entités

Par contre, les articles et les clients ne peuvent pas être regroupés : leurs informations ne sont pas homogènes (un article ne possède pas d'adresse et un client ne possède pas de prix unitaire). Il faut donc leur réserver deux entités distinctes : l'entité articles et l'entité clients.

Une association est une liaison qui a une signification précise entre plusieurs entités. Dans notre exemple, l'association commander est une liaison évidente entre les entités articles et clients, tandis que l'association livrer établit le lien sémantique entre les entités articles et fournisseurs.

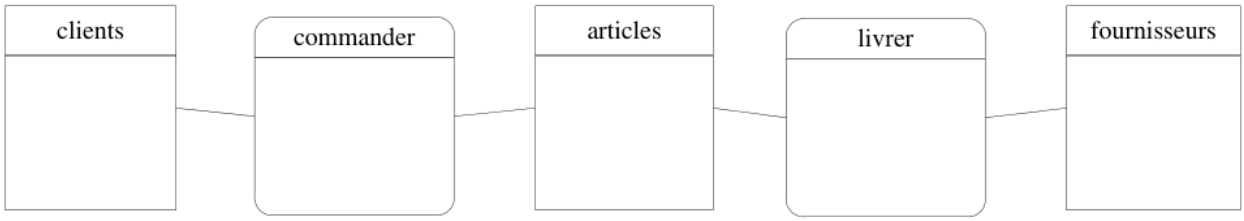


Fig. 2 – Associations

Remarquons que dans ce schéma, les entités clients et fournisseurs ne sont pas liées directement, mais indirectement, via l'entité articles, ce qui est assez naturel.

1.1.2 Attributs et identifiants

Un attribut est une propriété d'une entité ou d'une association.

Toujours dans notre exemple (figure 3), le prix unitaire est un attribut de l'entité articles, le nom de famille est un attribut de l'entité clients, la quantité commandée est un attribut de l'association commander et la date de livraison est un attribut de l'association livrer.



Fig. 3 – Attributs

Une entité et ses attributs ne doivent traiter que d'un seul sujet afin d'assurer une certaine cohérence au modèle. Dans notre exemple, il est donc préférable de ne pas mettre les informations relatives aux fournisseurs dans l'entité des articles mais plutôt dans une entité fournisseurs séparées (et liée à l'entité articles via l'association livrer).

Ensuite, chaque individu d'une entité doit être identifiable de manière unique. C'est pourquoi toutes les entités doivent posséder un attribut sans doublon (c'est-à-dire ne prenant pas deux fois la même valeur). Il s'agit de l'identifiant que l'on souligne sur le schéma, par convention. Le numéro de client constitue un identifiant classique pour l'entité clients (figure 4).



Fig. 4 – Identifiants

Remarques : – une entité possède au moins un attribut (son identifiant) ; – au contraire, une association peut être dépourvue d'attribut.

1.1.3 Cardinalités

La cardinalité d'un lien entre une entité et une association précise le minimum et le maximum de fois qu'un individu de l'entité peut être concerné par l'association.

Exemple : un client a au moins commandé un article et peut commander n articles (n étant indéterminé), tandis qu'un article peut avoir été commandé entre 0 et n fois (même si ce n'est pas le même n que précédemment). On obtient alors le schéma entités-associations complet 1 (figure 5).

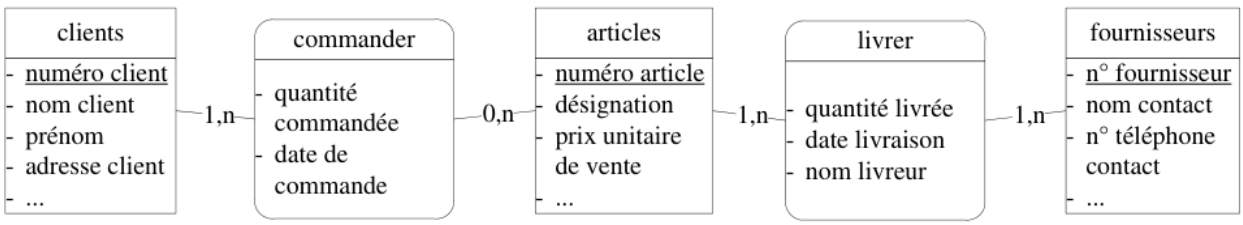


Fig. 5 – Cardinalités

Une cardinalité minimale de 1 doit se justifier par le fait que les individus de l'entité en question ont besoin de l'association pour exister (un client n'existe pas avant d'avoir commandé quoique ce soit, donc la cardinalité minimale de l'entité clients dans l'association commander est 1). Dans tous les autres cas, la cardinalité minimale vaut 0 (c'est le cas pour une liste pré-établie d'articles par exemple).

Ceci dit, la discussion autour d'une cardinalité minimale 0 ou 1 n'est vraiment intéressante que

lorsque la cardinalité maximale est 1. Nous verrons en effet lors de la traduction vers un schéma relationnel (section 2.3), que lorsque la cardinalité maximale est n, nous ne pouvons pas faire la différence entre une cardinalité minimale de 0 et une cardinalité minimale de 1.

Notons que sur notre exemple, un article peut être commandé par plusieurs clients. Cela provient du fait que tous les crayons rouges ne sont pas numérotés individuellement, mais portent un numéro d'article collectif. En toute rigueur, notre entité articles aurait du s'appeler types d'article. Ainsi, un crayon rouge peut être commandé par plusieurs clients, ce n'est simplement pas le même crayon à chaque fois. Il s'agit d'un choix de modélisation, le lecteur peut très légitimement faire le choix inverse qui consiste à numéroter individuellement chaque crayon rouge.

La seule difficulté pour établir correctement les cardinalités est de se poser les questions dans le bon sens. Autour de l'association commander, par exemple : – côté clients, la question est ((un client peut commander combien d'articles ?)) et la réponse est ((entre 1 et plusieurs)) ; – côté articles, la question est ((un article peut être commandé par combien de client ?)) et cette fois-ci, la réponse est ((entre 0 et plusieurs)).

1. Le lecteur avisé aura noté que le schéma de la figure 5 comporte des erreurs de conception. Ces erreurs seront corrigées dans la section 1.2 dédiée à la normalisation des schémas entités-associations.

1.1.4 Associations plurielles

Deux mêmes entités peuvent être plusieurs fois en association (c'est le cas sur la figure 6).

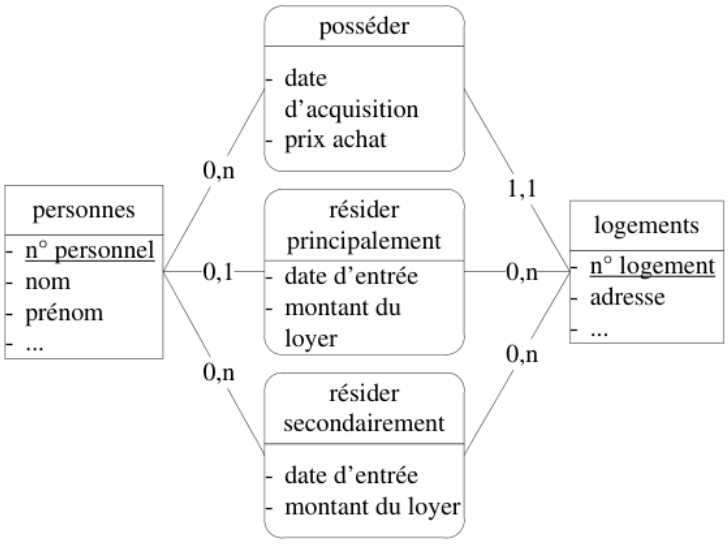


Fig. 6 – Associations plurielles

Dans cet exemple issu d'une agence immobilière, une personne peut être propriétaire, résider principalement ou résider secondairement dans un logement géré par l'agence. Les logements qui ne sont pas gérés par l'agence ne figurent pas dans l'entités des logements, ce qui explique certaines cardinalités 0 du schéma. Nous supposons également qu'un logement n'est détenu que par une seule personne et que ce propriétaire figure obligatoirement dans l'entité des personnes.

1.1.5 Association réflexive

Il est permis à une association d'être branchée plusieurs fois à la même entité, comme par

exemple l'association binaire réflexive de la figure 7.

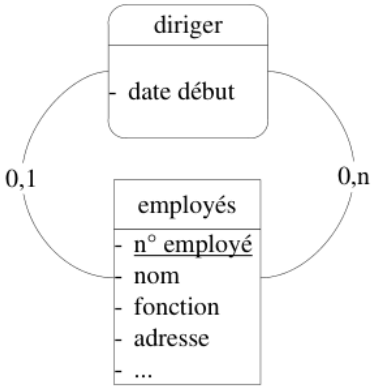


Fig. 7 – Association réflexive

Dans cet exemple, tout employé est dirigé par un autre employé (sauf le directeur général) et un employé peut diriger plusieurs autres employés, ce qui explique les cardinalités sur le schéma.

1.1.6 Associations non binaires

Lorsqu'autour d'une entité, toutes les associations ont pour cardinalités maximales 1 au centre et n à l'extérieur, cette entité est candidate pour être remplacée par une association branchée à toutes les entités voisines avec des cardinalités identiques 0,n.

La deuxième condition qu'il faut impérativement satisfaire est la règle de normalisation des attributs des associations (section suivante). Cette règle conduit parfois à l'apparition d'associations qui établissent un lien sémantique entre 3 entités ou plus.

Sur l'exemple de la figure 8 issu d'un cinéma, l'entité projections est uniquement entourée d'associations dont les cardinalités maximales sont 1 côté projections et n de l'autre côté. De plus, la donnée d'un créneau, d'un film et d'une salle suffit à déterminer une projection unique [2] . On peut donc la remplacer par une association projeter branchée aux trois entités salles, créneaux horaires et films. On parle alors d'association ternaire.

Fig. 8 – Entité remplaçable par une association ternaire

2. sans la date dans l'entité créneaux horaires, la donnée d'un créneau, d'un film et d'une salle aurait déterminé plusieurs projections et l'association ternaire n'aurait pas pu se faire

La difficulté de concevoir une association ternaire (ou plus) directement est d'établir les bonnes cardinalités. Il est donc conseillé d'en passer par un schéma entités-associations dans lequel on ne trouve que des associations binaires, puis de repérer les entités remplaçables par des associations, comme sur la figure 8 à gauche.

Cette règle de conduite permet d'éviter d'introduire une association ternaire abusive, par exemple entre les avions, les pilotes et les vols (figure 9), car le concepteur peut s'apercevoir que l'une des cardinalités maximales ne convient pas.

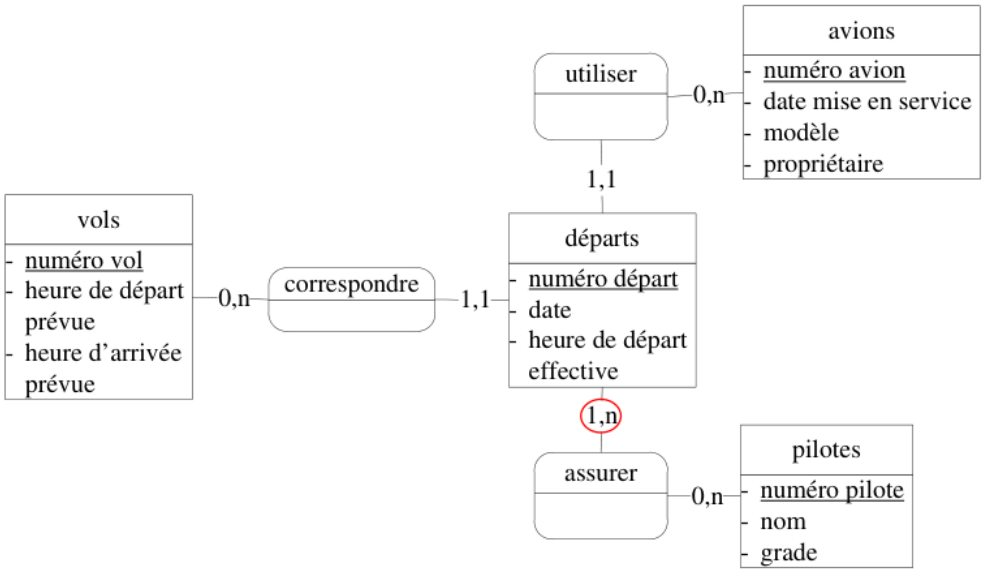


Fig. 9 – Contre-exemple : l'entité départs n'est pas remplaçable par une association ternaire

Par ailleurs, une association peut être branchée à plus de trois entités, comme sur la figure 10. Làencore, le conseil pour être sûr de la légitimité de cette association 4-aire, est de vérifier les cardinalités sur un schéma intermédiaire faisant apparaître à la place, une entité occupations et quatre associations binaires.

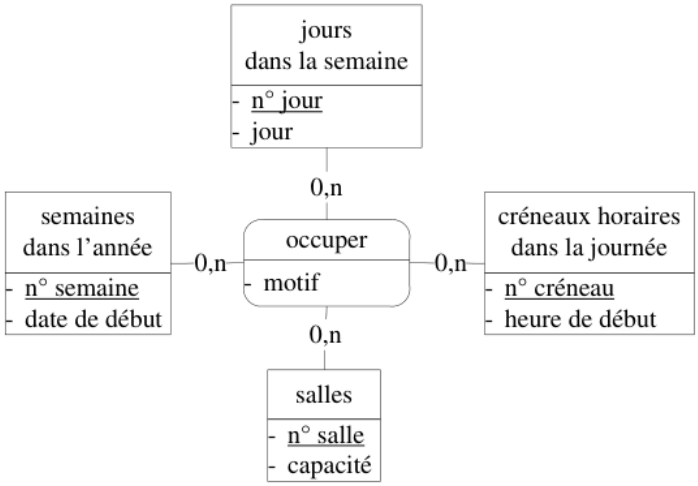


Fig. 10 – Exemple d'entité quaternaire ou 4-aire

1.2 Règles de normalisation

Un bon schéma entités-associations doit répondre à 9 règles de normalisation, que le concepteur doit connaître par cœur.

1.2.1 Les bonnes manières dans un schéma entités-associations

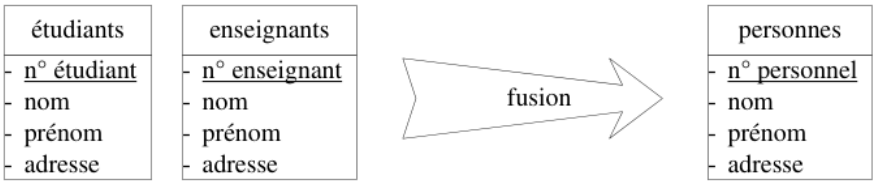
Normalisation des entités (importante) : toutes les entités qui sont remplaçables par une association doivent être remplacées (comme sur la figure 8).

Normalisation des noms : le nom d'une entité, d'une association ou d'un attribut doit être unique.

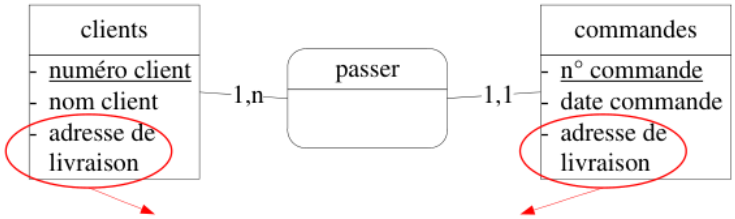
Conseils : – pour les entités, utiliser un nom commun au pluriel (par exemple : clients) ; – pour les associations, utiliser un verbe à l'infinitif (par exemple : effectuer, concerner) éventuellement à la forme passive (être commandé) et accompagné d'un adverbe (avoir lieu dans, pendant, à) ;

– pour les attributs, utiliser un nom commun singulier (par exemple : nom, numéro, libellé, description) éventuellement accompagné du nom de l'entité ou de l'association dans laquelle il se trouve (par exemple : nom de client, numéro d'article).

Remarque : lorsqu'il reste plusieurs fois le même nom, c'est parfois symptomatique d'une modélisation qui n'est pas terminée (figure 11(a)) ou le signe d'une redondance (figure 11(b)).



(a) Deux entités homogènes peuvent être fusionnées



redondance, donc risque d'incohérence

(b) Si deux attributs contiennent les mêmes informations, alors la redondance induit non seulement un gaspillage d'espace mais également un grand risque d'incohérence : ici, les adresses risquent de ne pas être les mêmes et dans ces conditions, où faut-il livrer ?

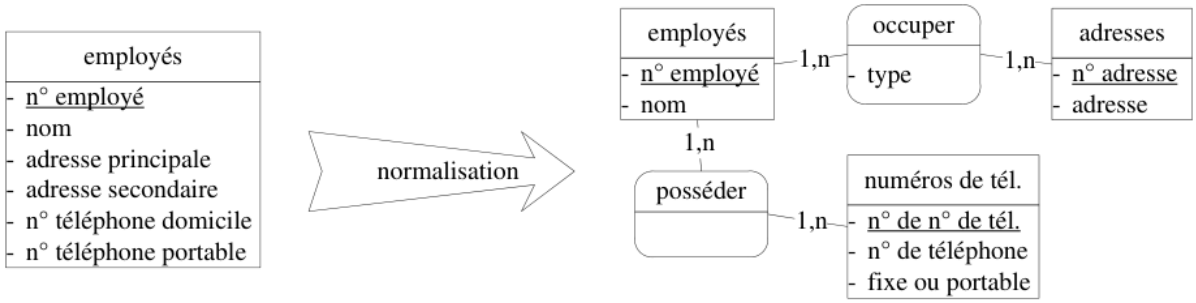
Fig. 11 – Contre-exemples de la normalisation des noms

Normalisation des identifiants : chaque entité doit posséder un identifiant.

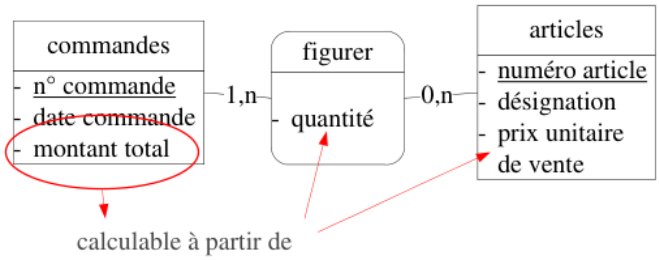
Conseils : – éviter les identifiants composés de plusieurs attributs (comme par exemple un identifiant formé par les attributs nom et prénom), car d'une part c'est mauvais pour les performances et d'autres part, l'unicité supposée par une telle démarche finit tôt ou tard par être démentie ; – préférer un identifiant court pour rendre la recherche la plus rapide possible (éviter notamment les chaînes de caractères comme un numéro de plaque d'immatriculation, un numéro de sécurité sociale ou un code postal 3) ; – éviter également les identifiants susceptibles de changer au cours du temps (comme les plaques d'immatriculation ou les numéros de sécurité sociale provisoires). Conclusion : l'identifiant sur un schéma entités-associations (et donc la future clé primaire dans le schéma relationnel) doit être un entier, de préférence incrémenté automatiquement 4 .

Normalisation des attributs (importante) : remplacer les attributs en plusieurs exemplaires en une association supplémentaire de cardinalités maximales n et ne pas ajouter d'attribut calculable à partir d'autres attributs.

En effet, d'une part, les attributs en plusieurs exemplaires posent des problèmes d'évolutivité du modèle (sur la figure 12(a) à gauche, comment faire si un employé a deux adresses secondaires ?) et



(a) Attributs en plusieurs exemplaires remplacés par une association supplémentaire



(b) Attribut calculable qu'il faut retirer du schéma

Fig. 12 – Contre-exemples de la normalisation des attributs

d'autre part, les attributs calculables induisent un risque d'incohérence entre les valeurs des attributs de

3. Un numéro de sécurité sociale, un code postal ou un numéro de téléphone sont bien des chaînes de caractères, même si elles ne comportent que des chiffres, tout simplement parce que ces numéros peuvent commencer par un 0, ce qui, en informatique, n'est pas possible avec un entier. 4. Le seul inconvénient de cette numérotation arbitraire est qu'il devient possible à une table de posséder deux fois la même ligne (avec deux numéros différents). Le conseil reste pourtant largement avantageux

base et celles des attributs calculés, comme sur la figure 12(b).

D'autres d'attributs calculables classiques sont à éviter, comme l'âge (qui est calculable à partir de la date de naissance) ou encore le département (calculable à partir d'une sous-chaîne du code postal).

Normalisation des attributs des associations (importante) : les attributs d'une association doivent dépendre directement des identifiants de toutes les entités en association.

Par exemple, sur la figure 5 la quantité commandée dépend à la fois du numéro de client et du numéro d'article, par contre la date de commande non. Il faut donc faire une entité commandes à part, idem pour les livraisons (figure 13).

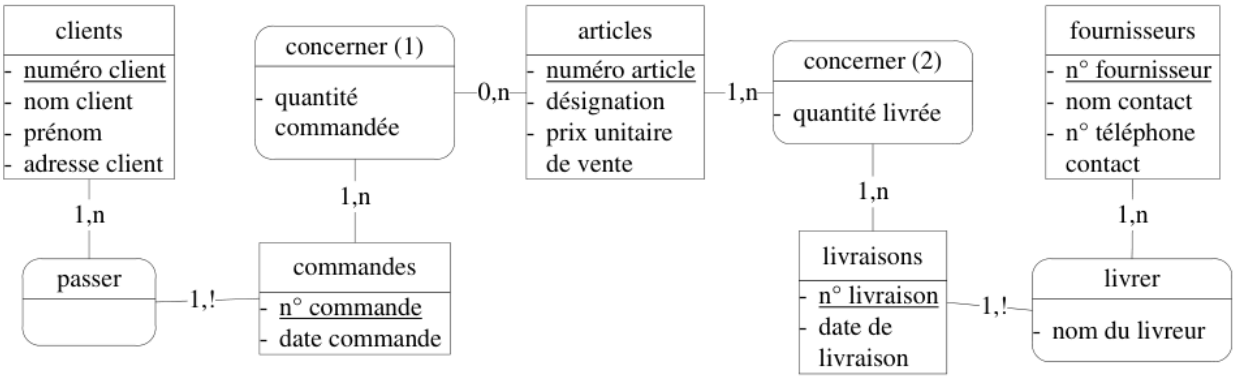


Fig. 13 – Normalisation des attributs des associations

L'inconvénient de cette règle de normalisation est qu'elle est difficile à appliquer pour les associations qui ne possèdent pas d'attribut. Pour vérifier malgré tout qu'une association sans attribut est bien normalisée, on peut donner temporairement à cette association un attribut imaginaire (mais pertinent) qui permet de vérifier la règle.

Par exemple, entre les entités livres et auteurs de la figure 16, l'association écrire ne possède pas d'attribut. Imaginons que nous ajoutions un attribut pourcentage qui contient le pourcentage du livre écrit par chaque auteur (du même livre). Comme cet attribut pourcentage dépend à la fois du numéro de livre et du numéro d'auteur, l'association écrire est bien normalisée.

Autre conséquence de la normalisation des attributs des associations : une entité avec une cardinalité de 1,1 ou 0,1 aspire les attributs de l'association (figure 14).

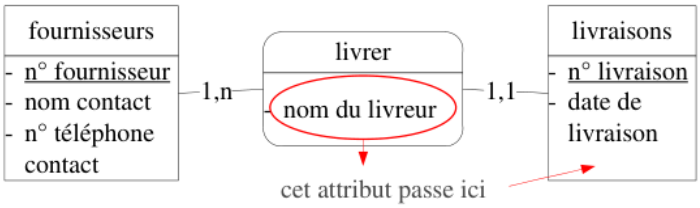
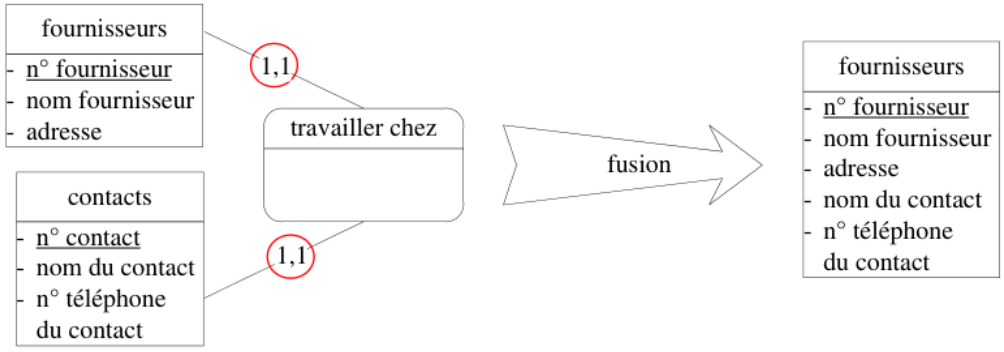
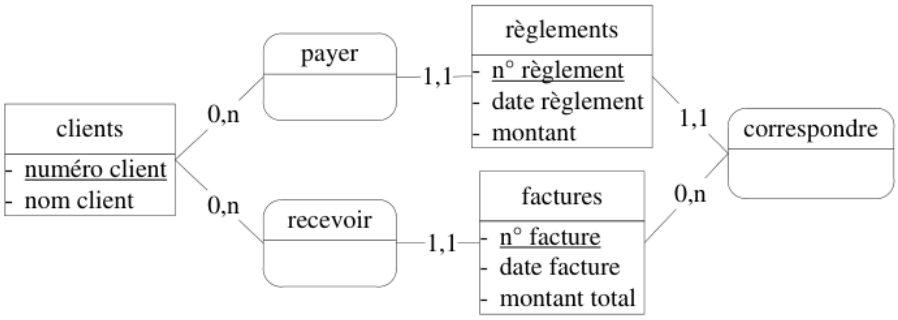


Fig. 14 – Cardinalité 1,1 et attributs d'une association

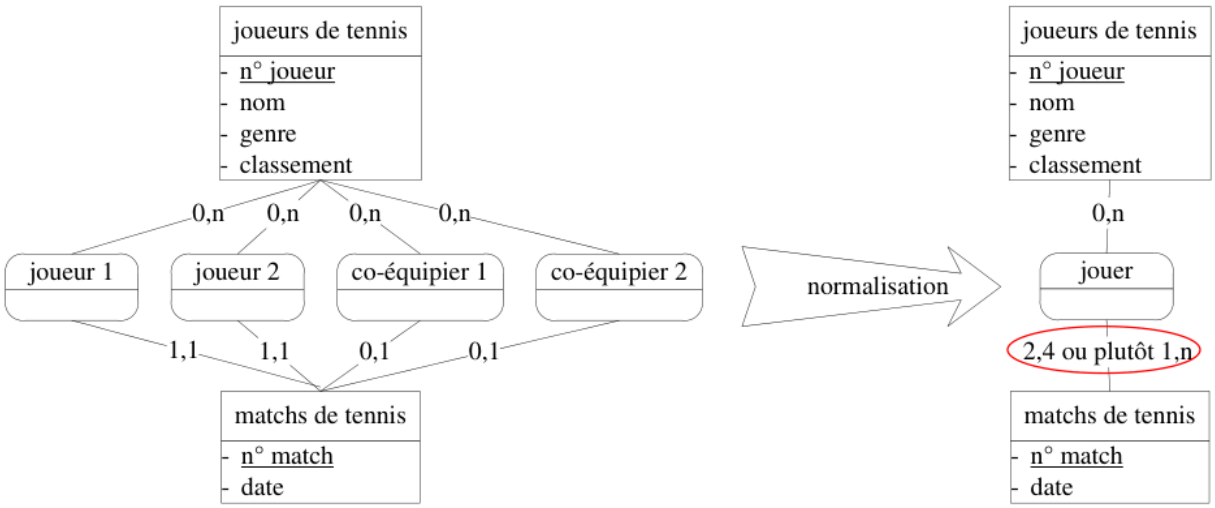
Normalisation des associations (importante) : il faut éliminer les associations fantômes (figure 15(a)), redondantes (figure 15(b)) ou en plusieurs exemplaires (figure 15(c)).



(a) les cardinalités sont toutes 1,1 donc c'est une association fantôme



(b) si un client ne peut pas régler la facture d'un autre client, alors l'association payer est inutile et doit être supprimée (dans le cas contraire, l'association payer doit être maintenue)



(c) une association suffit pour remplacer les 4 associations participer en tant que ...

Fig. 15 – Contre-exemples de la normalisation des associations

En ce qui concerne les associations redondantes, cela signifie que s'il existe deux chemins pour se rendre d'une entité à une autre, alors ils doivent avoir deux significations ou deux durées de vie différentes. Sinon, il faut supprimer le chemin le plus court, car il est déductible à partir de l'autre chemin. Dans notre exemple de la figure 15(b), si on supprime l'association payer, on peut retrouver le client qui a payé le règlement en passant par la facture qui correspond.

Remarque : une autre solution pour le problème de la figure 15(b) consiste à retirer l'entité règlements et d'ajouter une association régler avec les mêmes attributs (sauf l'identifiant) entre les entités clients et factures.

Normalisation des cardinalités : une cardinalité minimale est toujours 0 ou 1 (et pas 2, 3 ou n) et une cardinalité maximale est toujours 1 ou n (et pas 2, 3, ...).

Cela signifie que si une cardinalité maximale est connue et vaut 2, 3 ou plus (comme sur la figure 15(c) à droite, ou pour un nombre limité d'emprunts dans une bibliothèque), alors nous considérons quand même qu'elle est indéterminée et vaut n. Cela se justifie par le fait que même si nous connaissons n au moment de la conception, il se peut que cette valeur évolue au cours du temps. Il vaut donc mieux considérer n comme une inconnue dès le départ.

Cela signifie également qu'on ne modélise pas les cardinalités minimales qui valent plus de 1 car ce genre de valeur est aussi amenée à évoluer. Par ailleurs, avec une cardinalité maximale de 0, l'association n'aurait aucune signification.

Dans un SGBD relationnel, nous pourrions assurer les cardinalités valant 2, 3 ou plus, via

l'utilisation de déclencheurs. Mais cette notion n'est pas abordée dans ce document qui se contente, au contraire, de décrire ce qu'il est possible de faire sans utiliser de déclencheur.

1.2.2 Les formes normales

À ces 6 règles de normalisation, il convient d'ajouter les 3 premières formes normales traditionnellement énoncées pour les schémas relationnels, mais qui trouvent tout aussi bien leur place en ce qui concerne les schémas entités-associations.

Première forme normale : à un instant donné dans une entité, pour un individu, un attribut ne peut prendre qu'une valeur et non pas, un ensemble ou une liste de valeurs.

Si un attribut prend plusieurs valeurs, alors ces valeurs doivent faire l'objet d'une entité supplémentaire, en association avec la première (figure 16).

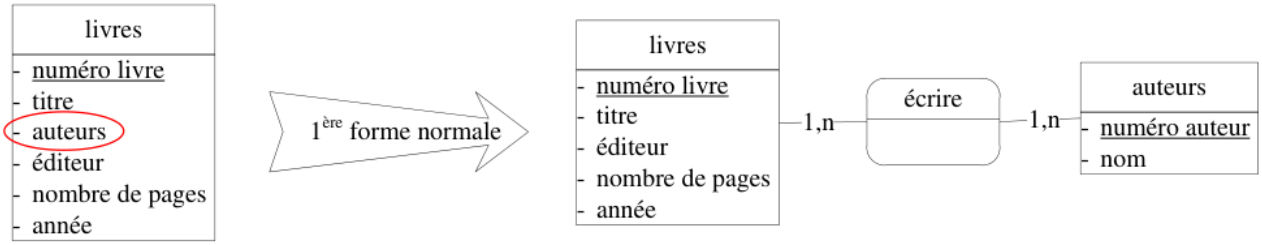


Fig. 16 – Application de la première forme normale : il peut y avoir plusieurs auteurs pour un livre donné

Deuxième forme normale : l'identifiant peut être composé de plusieurs attributs mais les autres attributs de l'entité doivent dépendre de l'identifiant en entier (et non pas une partie de cet identifiant).

Cette deuxième forme normales peut être oubliée si on suit le conseil de n'utiliser que des identifiants non composés et de type entier. En vérité, elle a été vidée de sa substance par la règle de normalisation des attributs des associations (page 12).

Considérons malgré tout le contre-exemple suivant : dans une entité clients dont l'identifiant est composé des attributs nom et prénom, la date de fête d'un client ne dépend pas de son identifiant en entier mais seulement de prénom. Elle ne doit pas figurer dans l'entité clients, il faut donc faire une entité calendrier à part, en association avec l'entité clients.

Troisième forme normale de Boyce-Codd (importante) : tous les attributs d'une entité doivent dépendre directement de son identifiant et d'aucun autre attribut.

Si ce n'est pas le cas, il faut placer l'attribut pathologique dans une entité séparée, mais en association avec la première.

numéro avion	constructeur	modèle	capacité	propriétaire
1	Airbus	A380	180	Air France
2	Boeing	B747	314	British Airways
3	Airbus	A380	180	KLM

Tab. 1 – Il y a redondance (et donc risque d'incohérence) dans les colonnes constructeur et capacité

Par exemple, l'entité avions (figure 17 à gauche) dont les valeurs sont données dans le tableau 1, n'est pas en troisième forme normale de Boyce-Codd, car la capacité et le constructeur d'un avion ne dépendent pas du numéro d'avion mais de son modèle. La solution normalisée est donnée figure 17 à droite.

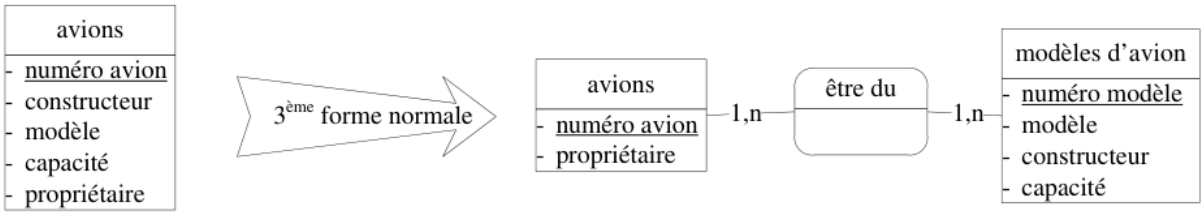


Fig. 17 – Application de la troisième forme normale de Boyce-Codd

1.3 Dépendances fonctionnelles

Pour établir efficacement un modèle entités-associations bien normalisé, on peut étudier au préalable les dépendances fonctionnelles entre les attributs puis, les organiser en graphe de couverture minimale. Cette technique est traditionnellement employée pour normaliser des schémas relationnels, mais elle s'applique très bien en amont, au niveau des modèles conceptuels.

1.3.1 Définitions et propriétés

Un attribut Y dépend fonctionnellement d'un attribut X si et seulement si une valeur de X induit une unique valeur de Y . On note une dépendance fonctionnelle par une flèche simple : $X \rightarrow Y$.

Par exemple, si X est le numéro de client et Y le nom de client, alors on a bien $X \rightarrow Y$. Par contre, on a pas $Y \rightarrow X$, car plusieurs clients de numéros différents peuvent porter le même nom.

Transitivité : si $X \rightarrow Y$ et $Y \rightarrow Z$ alors $X \rightarrow Z$.

Par exemple, on a numéro de commande → numéro de client → nom de client, donc on a aussi numéro de commande → nom de client. Mais la dépendance fonctionnelle numéro de commande → nom de client est dite transitive, car il faut passer par le numéro de client pour l'obtenir.

Au contraire, la dépendance fonctionnelle numéro de client → nom de client est directe . Seules les dépendances fonctionnelles directes nous intéressent. D'autres exemples sont données dans le tableau 2.

dépendance fonctionnelle	directe ?
numéro de livraison → date de livraison	oui
numéro de livraison → numéro du fournisseur	oui
numéro du fournisseur → nom du fournisseur	oui
numéro de livraison → nom du fournisseur	non

Tab. 2 – Exemples de dépendances fonctionnelles

Un attribut Y peut avoir une dépendance fonctionnelle qui repose sur la conjonction de plusieurs attributs, auquel cas la dépendance est dite non élémentaire . Les dépendances fonctionnelles non élémentaires sont notées par une flèche unique mais comportant plusieurs points d'entrée (regroupés autour d'un cercle).

Par exemple, la quantité commandée (d'un article dans une commande) dépend de deux attributs : le numéro de commande et le numéro d'article (figure 18). Notons que cette dépendance numéro de commande + numéro d'article → quantité est à la fois non élémentaire et directe.

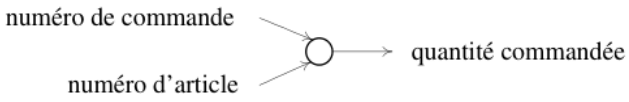
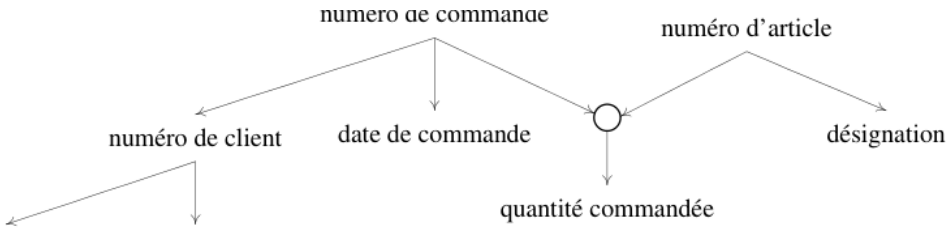


Fig. 18 – Dépendance fonctionnelle non élémentaire, mais directe

1.3.2 Graphe de couverture minimale

En représentant tous les attributs et toutes les dépendances fonctionnelles directes entre eux, nous obtenons un réseau appelé graphe de couverture minimale. Dans notre exemple sur les clients, les commandes et les articles, ce graphe est donné sur la figure 19.



adresse du client

nom du client

Fig. 19 – Graphe de couverture minimale

La technique de traduction en un schéma entités-associations qui suit, suppose qu'aucun attribut n'a été oublié sur le graphe de couverture minimal et notamment, aucun identifiant. D'ailleurs toutes les dépendances fonctionnelles du graphe doivent partir d'un identifiant. Si ce n'est pas le cas, c'est qu'un identifiant a été omis.

1.3.3 Traduction vers un schéma entités-associations

À partir du graphe de couverture minimale (figure 19), le schéma entités-associations normalisé correspondant apparaît naturellement (figure 20), en suivant quelques étapes simples.

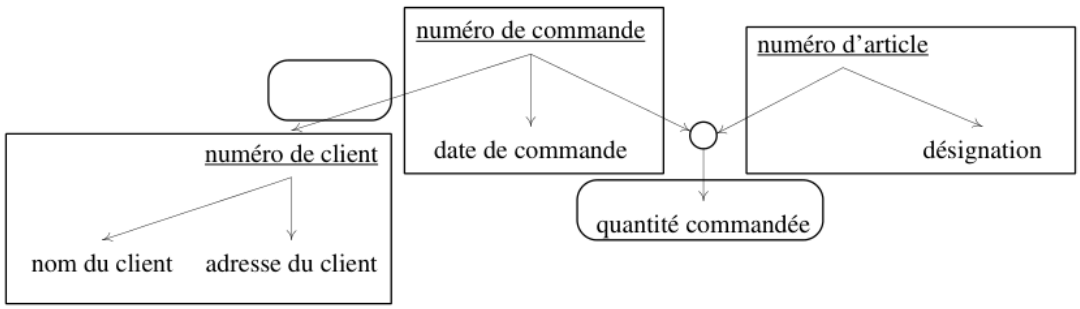


Fig. 20 – Identification des entités et des associations sur un graphe de couverture minimale

Étape 1 : il faut repérer et souligner les identifiants.

Étape 2 : puis tous les attributs non identifiant qui dépendent directement d'un identifiant et d'un seul, forment une entité (avec l'identifiant, bien sûr).

Étape 3 : ensuite, les dépendances élémentaires entre les identifiants forment des associations binaires dont les cardinalités maximales sont 1 au départ de la dépendance fonctionnelle et n à l'arrivée.

Étape 4 : sauf si entre deux identifiants se trouvent deux dépendances élémentaires réflexives 5 , auquel cas l'association binaire a deux cardinalités maximales valant 1.

5. c'est à cause de cette étape 4 qu'il est préférable de ne pas traduire directement le graphe de

couverture minimale en un schéma relationnel, cf. les commentaires de la règle 4 page 25

Étape 5 : enfin, les attributs (non identifiants) qui dépendent de plusieurs identifiants sont les attributs d'une association supplémentaire dont les cardinalités maximales sont toutes n.

La traduction du graphe de couverture minimale de la figure 20 en un schéma entités-associations normalisé est donnée sur la figure 21.

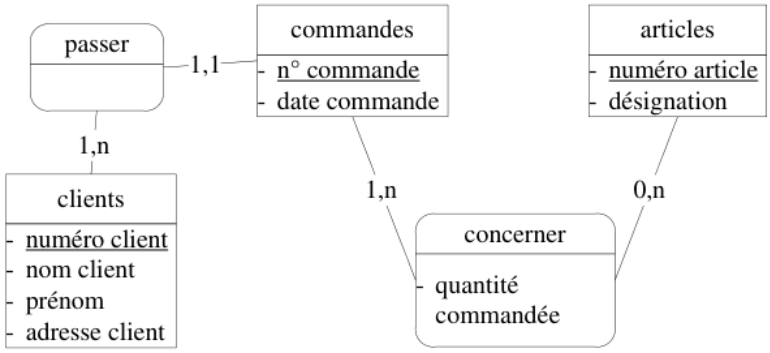


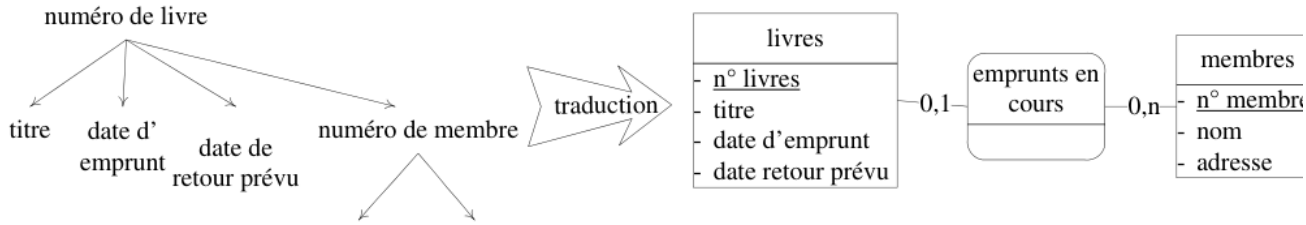
Fig. 21 – Schéma entités-associations normalisé obtenu à partir du graphe de couverture minimale

Dans ce genre de traduction, il faut donner un nom aux entités et aux associations, car ce n'est pas le cas sur le graphe de couverture minimale et il reste les cardinalités minimales à établir.

Remarquons également qu'en réalité, il faut déjà connaître les entités en présence pour établir correctement le graphe de couverture minimale, ne serait-ce que pour y faire figurer leurs identifiants. Donc finalement, cette technique n'est une aide pour établir les associations entre les entités et pour normaliser les entités et leurs associations (jusqu'en troisième forme normale de Boyce-Codd).

1.3.4 Gestion des dates et du caractère historique

Dans une bibliothèque, on peut vouloir stocker les emprunts en cours (figure 22) et/ou les emprunts historiques (figure 23). Pour les emprunts en cours, la date de retour prévu est un attribut de l'entité



adresse

nom

Fig. 22 – Sans historisation des emprunts, pas de problème

livres car un livre ne peut faire l'objet que d'un seul emprunt en cours. Dans ce cas, l'établissement du graphe de couverture minimal ne pose aucun problème.

Par contre, un livre peut faire l'objet de plusieurs emprunts historiques et dans ces conditions, la date d'emprunt est déterminante pour connaître la date de retour prévue (figure 23 en haut à gauche). Or une date n'est pas un identifiant 6 et une dépendance fonctionnelle ne peut partir que d'un ou plusieurs identifiant(s). C'est le signe qu'il manque un identifiant : le numéro d'emprunt (figure 23 en haut à droite).

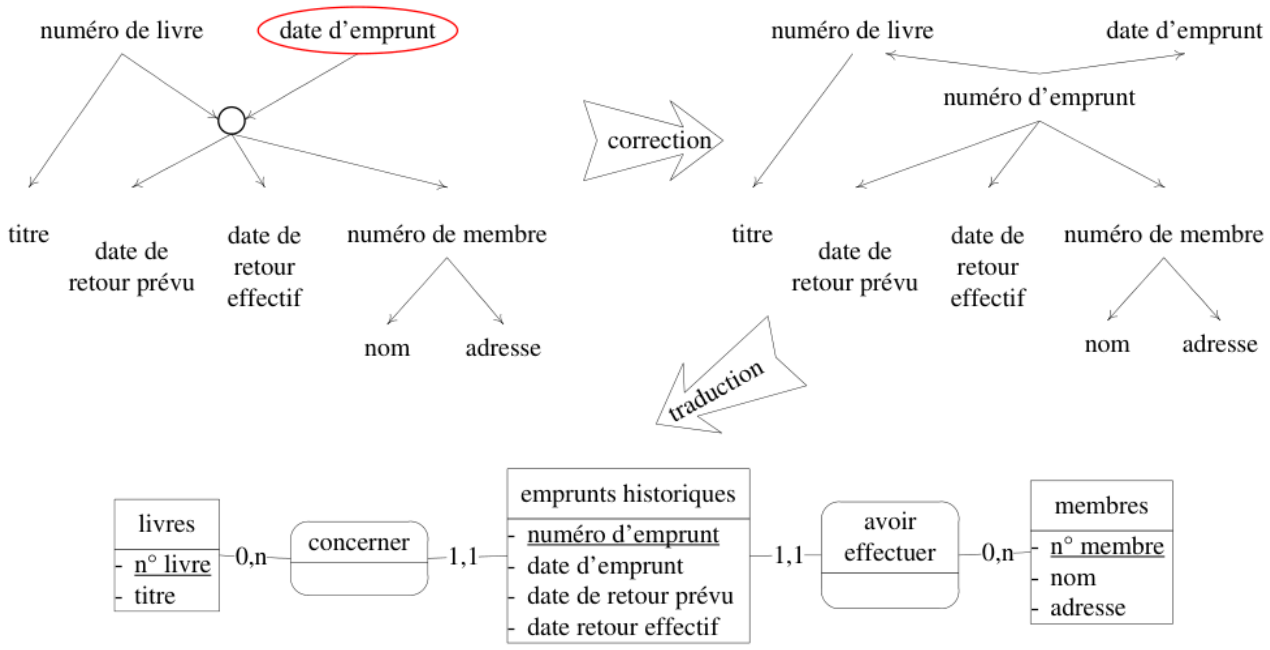


Fig. 23 – Même pour une entité historisée, il vaut mieux éviter que la date n'entre dans l'identifiant

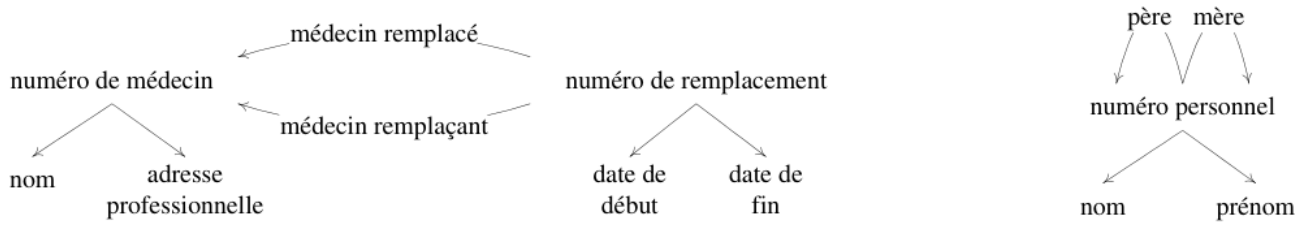
Notons que l'entité emprunts historiques supplémentaire qui apparaît après traduction (figure 23 en bas) ne peut pas être transformée en une association comme on pourrait le croire au simple examen des cardinalités qui l'entourent. En effet, les attributs de l'association qui en résulterait ne vérifieraient pas la normalisation des attributs des associations. Notamment, la date de retour effectif ne dépend pas du numéro de livre et du numéro de membre, mais du numéro de livre et de la date d'emprunt.

La normalisation des entités ne s'applique donc pas aux entités qui ont un caractère historique. À moins que les dates ne soient regroupées dans une entité séparée, ce qui n'est pas conseillé tant qu'aucune information liée aux dates (comme le caractère férié, par exemple) n'est nécessaire.

6. Si on suit le précieux conseil de n'utiliser que des entiers arbitraires et auto-incrémentés comme identifiant.

1.3.5 Dépendances plurielles et réflexives

Une ou plusieurs dépendances fonctionnelles peuvent partir ou arriver plusieurs fois du même attribut. Pour clarifier la signification de chaque dépendance fonctionnelle, on peut ajouter un commentaire sur la flèche (figure 24). Ce commentaire sert ensuite à donner un nom aux associations correspondantes.



(a) dépendances plurielles

(b) dépendances réflexives

Fig. 24 – Dépendances fonctionnelles commentées

Les dépendances fonctionnelles plurielles entre les médecins et le remplacements (figure 24(a))

deviennent, après traduction, des associations plurielles entre les entités médecins et remplacements. Notons que l'entité remplacements ainsi générée, a aussi un caractère historique.

Les fonctionnelles réflexives (X → X), quoique toujours vraies, ne présentent aucun intérêt, à moins qu'elles aient une signification particulière. Un exemple de dépendance réflexive licite sur un graphe de couverture minimale est la dépendance fonctionnelle personne → personne, lorsqu'elle signifie ((diriger)), ((être en couple avec)) ou ((être le père ou la mère de)) (figure 24(b)).

Dans le même ordre d'idée, il est inutile de faire figurer sur le graphe de couverture minimal des dépendances fonctionnelles non élémentaires vraies, mais idiotes, comme par exemple numéro de commande + numéro d'article → numéro de commande.

1.3.6 Associations sans attributs

La lacune majeure de cette méthode reste tout de même le fait que les associations dont toutes les cardinalités maximales sont n mais qui sont sans attribut ne figurent pas sur le graphe de couverture minimale. Il faut alors, soit leur inventer temporairement un attribut (comme pour la normalisation des attributs des associations), soit introduire une notation spéciale (par exemple, une dépendance non élémentaire qui ne débouche sur aucun attribut).

Pour illustrer ce défaut, prenons l'exemple des films et des acteurs (figure 25). Il n'y a pas d'attribut

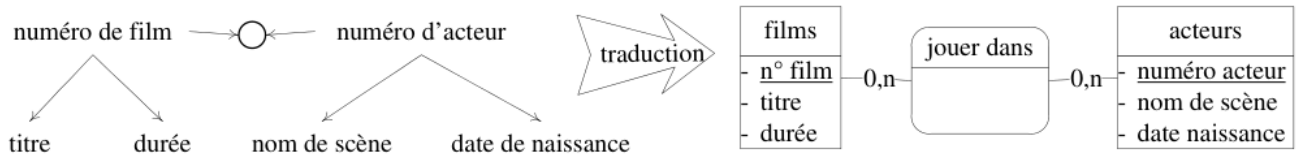


Fig. 25 – Utilisation d'une dépendance non élémentaire et sans enfant sur un graphe de couverture minimal

qui dépende à la fois du numéro de film et du numéro d'acteur (à moins d'imaginer le temps d'apparition à l'écran). Et pourtant, les deux entités films et acteurs sont en association. Grâce à la dépendance non élémentaire et sans enfant, on peut rendre compte de cette situation sur le graphe de couverture minimale et faire ainsi apparaître l'association sur le schéma entités-associations qui en est traduit.

1.4 Méthodologie de base

Face à une situation bien définie (soit à travers un énoncé précis, soit à travers une collection de formulaires ou d'états que le nouveau système d'information est censé remplacer), nous pouvons procéder sans établir le graphe de couverture minimale :

– identifier les entités en présence ; – lister leurs attributs ; – ajouter les identifiants (numéro arbitraire et auto-incrémenté) ;

– établir les associations binaires entre les entités ; – lister leurs attributs ;

– calculer les cardinalités ;

– vérifier les règles de normalisation et en particulier, la normalisation des entités (c'est à ce stade qu'apparaissent les associations non binaires), des associations et de leurs attributs ainsi que la troisième forme normale de Boyce-Codd ; – effectuer les corrections nécessaires.

Mais, il est parfois plus intuitif d'en passer par l'étude des dépendances fonctionnelles directes :

– identifier les entités en présence et leur donner un identifiant (numéro arbitraire et auto-incrémenté) ; – ajouter l'ensemble des attributs et leur dépendances fonctionnelles directes avec les identifiants (en commençant par les dépendances élémentaires) ; – traduire le graphe de couverture minimale obtenu en un schéma entités-associations ; – ajuster les cardinalités minimales et ;

– à ce stade, la majorité des règles de normalisation devraient être vérifiées, il reste tout de même la normalisation des noms, la présence d'attributs en plusieurs exemplaires et d'associations redondantes ou en plusieurs exemplaires, à corriger.

Il faut garder également à l'esprit que le modèle doit être exhaustif (c'est-à-dire contenir toutes les informations nécessaires) et éviter toute redondance qui, on ne le dira jamais assez, constitue une perte d'espace, une démultiplication du travail de maintenance et un risque d'incohérence.

Il faut par ailleurs veiller à éliminer les synonymes (plusieurs signifiants pour un signifié, exemple : nom, patronyme, appellation) et les polysèmes (plusieurs signifiés pour un signifiant, exemples : qualité, statut).

Il va de soi que cette méthodologie ne doit pas être suivie pas-à-pas une bonne fois pour toute. Au contraire, il faut itérer plusieurs fois les étapes successives, pour espérer converger vers une modélisation pertinente de la situation.

2 Modèle logique de données (MLD)

Maintenant que le MCD est établi, on peut le traduire en différents systèmes logiques et notamment les bases de données relationnelles qui proposent une vision plus concrète pour modéliser la situation.

2.1 Systèmes logiques

Avant l'apparition des systèmes de gestion de base de données (SGBD ou DBMS pour Data Base Management System), les données étaient stockées dans des fichiers binaires et gérées par des programmes exécutables (développés en Basic, Cobol ou Dbase, par exemple). [Gabay] propose à ce sujet une traduction d'un MPD vers un MLD fichier. Mais la maintenance des programmes (en cas de modification de la structure des données, notamment) était très problématique.

Sont alors apparus les SGBD hiérarchiques dans lesquels les données sont organisées en arbre (IMSDL1 d'IBM, par exemple), puis les SGBD réseaux dans lesquels les données sont organisées selon un graphe plus général (IDS2 de Bull, par exemple). [Matheron, Nanci et al., Gabay] décrivent la traduction d'un MPD vers un MLD Codasyl (base de données réseaux). Ces deux types de SGBD sont dit navigationnels car on peut retrouver l'information à condition d'en connaître le chemin d'accès.

Aujourd'hui, ils sont largement remplacés par les SGBD relationnels (SGBDR) avec lesquels l'information peut être obtenue par une requête formulée dans un langage quasiment naturel (la langage SQL pour Structured Query Langage). Parmi les SGBDR les plus répandus nous trouvons Oracle, SQL Server et DB2. Nous nous contentons ici d'exposer le modèle logique de données relationnel (MLDR).

Plus récemment, sont apparus le modèle logique orienté objet et même des SGBD orientés objets. Pourtant, les SGBD relationnels restent extrêmement majoritaires, tandis que l'approche orienté objet est parfaitement adaptée au développement d'applications clientes dynamiques et liées aux données du système d'information.

2.2 Modèle logique relationnel

Concentrons-nous désormais sur le MLDR.

2.2.1 Tables, lignes et colonnes

Lorsque des données ont la même structure (comme par exemple, les renseignements relatifs aux clients), on peut les organiser en table dans laquelle les colonnes décrivent les champs en commun et les lignes contiennent les valeurs de ces champs pour chaque enregistrement (tableau 3).

numéro client	nom	prénom	adresse
1	Dupont	Michel	127, rue...
2	Durand	Jean	314, boulevard...
3	Dubois	Claire	51, avenue...
4	Dupuis	Marie	2, impasse...
...	...	...	...

Tab. 3 – Contenu de la table clients, avec en première ligne les intitulés des colonnes

2.2.2 Clés primaires et clés étrangères

Les lignes d'une table doivent être uniques, cela signifie qu'une colonne (au moins) doit servir à les identifier. Il s'agit de la clé primaire de la table.

L'absence de valeur dans une clé primaire ne doit pas être autorisée. Autrement dit, la valeur vide (NULL) est interdite dans une colonne qui sert de clé primaire, ce qui n'est pas forcément le cas des autres colonnes, dont certaines peuvent ne pas être renseignées à toutes les lignes.

De plus, la valeur de la clé primaire d'une ligne ne devrait pas, en principe, changer au cours du temps.

Par ailleurs, il se peut qu'une colonne Colonne1 d'une table ne doive contenir que des valeurs prises par la colonne Colonne2 d'une autre table (par exemple, le numéro du client sur une commande doit correspondre à un vrai numéro de client). La Colonne2 doit être sans doublons (bien souvent il s'agit d'une clé primaire). On dit alors que la Colonne1 est clé étrangère et qu'elle référence la Colonne2.

Par convention, on souligne les clés primaires et on fait précéder les clés étrangères d'un dièse # dans la description des colonnes d'une table :

clients(numéro client, nom client, prénom, adresse client) commandes(numéro commande, date de commande, #numéro client (non vide))

Remarques : – une même table peut avoir plusieurs clés étrangères mais une seule clé primaire (éventuellement composées de plusieurs colonnes) ; – une colonne clé étrangère peut aussi être primaire (dans la même table) ; – une clé étrangère peut être composée (c'est le cas si la clé primaire référencée est composée) ; – implicitement, chaque colonne qui compose une clé primaire ne peut pas recevoir la valeur vide (NULL interdit) ; – par contre, si une colonne clé étrangère ne doit pas recevoir la valeur vide, alors il faut le préciser dans la description des colonnes.

Les SGBDR vérifient au coup par coup que chaque clé étrangère ne prend pas de valeurs en dehors de celles déjà prises par la ou les colonne(s) qu'elle référence. Ce mécanisme qui agit lors de l'insertion, de la suppression ou de la mise à jour de lignes dans les tables, garantit ce que l'on appelle l'intégrité référentielle des données.

2.2.3 Schéma relationnel

On peut représenter les tables d'une base de données relationnelle par un schéma relationnel dans lequel les tables sont appelées relations et les liens entre les clés étrangères et leur clé primaire est symbolisé par un connecteur (figure 26).

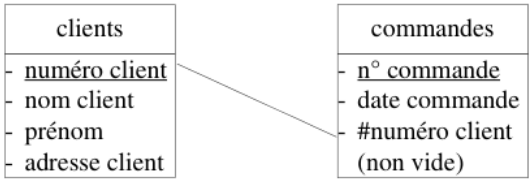


Fig. 26 – Schéma relationnel simple entre deux tables

Certains éditeur inscrivent sur le connecteur un symbole 1 côté clé primaire et un symbole ∞ côté clé étrangère (à condition que celle-ci ne soit pas déjà clé primaire). Il faut prendre garde avec cette convention, car le symbole ∞ se trouve du côté opposé à la cardinalité maximale n correspondante.

2.3 Traduction d'un MCD en un MLDR

Pour traduire un MCD en un MLDR, il suffit d'appliquer cinq règles.

Notations : on dit qu'une association binaire (entre deux entités ou réflexive) est de type : – 1 : 1 (un à un) si aucune des deux cardinalités maximales n'est n ; – 1 : n (un à plusieurs) si une des deux cardinalités maximales est n ; – n : m (plusieurs à plusieurs) si les deux cardinalités maximales sont n.

En fait, un schéma relationnel ne peut faire la différence entre 0,n et 1,n. Par contre, il peut la faire entre 0,1 et 1,1 (règles 2 et 4).

Règle 1 : toute entité devient une table dans laquelle les attributs deviennent les colonnes. L'identifiant de l'entité constitue alors la clé primaire de la table.

Par exemple, l'entité articles de la figure 13 devient la table :

articles(numéro article, désignation, prix unitaire de vente)

Règle 2 : une association binaire de type 1 : n disparaît, au profit d'une clé étrangère dans la table côté 0,1 ou 1,1 qui référence la clé primaire de l'autre table. Cette clé étrangère ne peut pas recevoir la valeur vide si la cardinalité est 1,1.

Par exemple, l'association livrer de la figure 13 est traduite par :

fournisseurs(n ◦ fournisseur, nom contact, n ◦ téléphone contact) livraisons(n ◦ livraison, date de livraison, nom livreur, #n ◦ fournisseur (non vide))

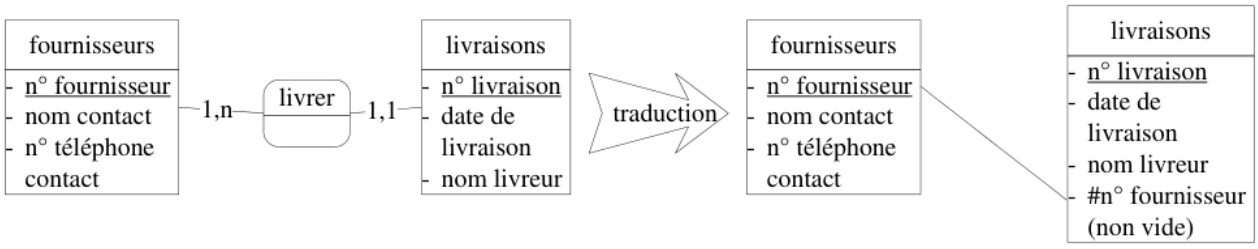


Fig. 27 – Traduction d'une association de type 1 : n

Il ne devrait pas y avoir d'attribut dans une association de type 1 : n, mais s'il en reste, alors ils glissent vers la table côté 1.

Règle 3 : une association binaire de type n : m devient une table supplémentaire (parfois appelée table de jonction, table de jointure ou table d'association) dont la clé primaire est composée de deux clés étrangères (qui référencent les deux clés primaires des deux tables en association). Les attributs de l'association deviennent des colonnes de cette nouvelle table.

Par exemple, l'association concerner (1) de la figure 13 est traduite par la table supplémentaire lignes de commande :

lignes de commande(#n ◦ commande, #n ◦ article, quantité commandée)

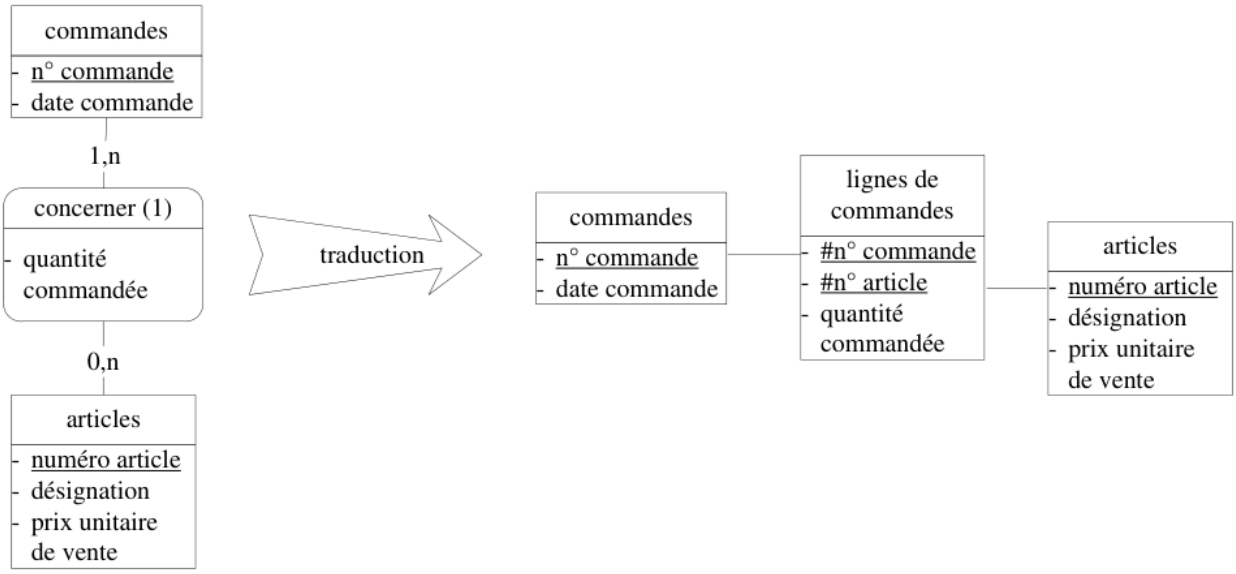


Fig. 28 – Traduction d'une association de type n : m

Règle 4 : une association binaire de type 1 : 1 est traduite comme une association binaire de type 1 : n sauf que la clé étrangère se voit imposer une contrainte d'unicité en plus d'une éventuelle contrainte de non vacuité (cette contrainte d'unicité impose à la colonne correspondante de ne prendre que des valeurs distinctes).

Si les associations fantômes ont été éliminées, il devrait y avoir au moins un côté de cardinalité 0,1. C'est alors dans la table du côté opposé que doit aller la clé étrangère. Si les deux côtés sont de cardinalité 0,1 alors la clé étrangère peut être placée indifféremment dans l'une des deux tables.

Par exemple, l'association diriger de la figure 29 est traduite par :

services(n ◦ service, nom service, #numéro employé (non vide, unique)) employés(numéro employés, nom)

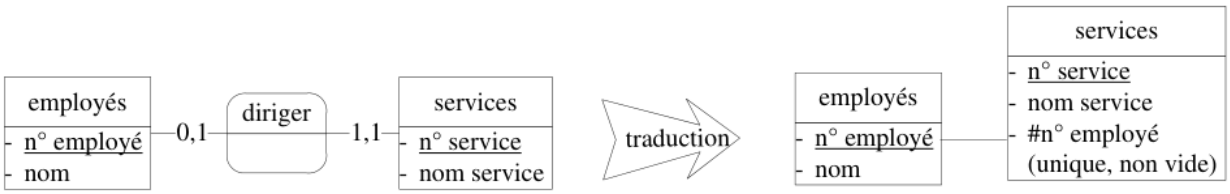


Fig. 29 – Traduction d'une association de type 1 : 1

En réalité, la règle 4 proposée ici considère qu'une association binaire de type 1 : 1 correspond à une association binaire de type 1 : n particulière. Une alternative consiste à voir une association binaire de type 1 : 1 comme une association binaire de type n : m particulière. Il suffit pour cela d'ajouter une contrainte d'unicité sur chacune des clés étrangères de la table de jonction supplémentaire :

services(n ◦ service, nom service) directions(#n ◦ service (unique), #numéro employé (unique) employés(numéro employés, nom)

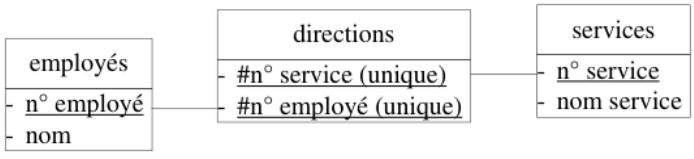


Fig. 30 – Traduction alternative d'une association de type 1 : 1

Mais rien ne garantit, dans cette traduction alternative (figure 30), qu'un service possède un dirigeant, alors que c'est obligatoire. La première traduction (figure 29) est donc préférable.

Remarque : d'autres techniques sont parfois proposées pour cette règle 4 (fusionner les tables, utiliser une clé primaire identique, utiliser deux clés étrangères réflexives) mais elles ne sont pas exploitables dans le cas général.

Règle 5 : une association non binaire est traduite par une table supplémentaire dont la clé primaire est composée d'autant de clés étrangères que d'entités en association. Les attributs de l'association deviennent des colonnes de cette nouvelle table.

Par exemple, l'association projeter de la figure 8 devient la table :

projections(#n ◦ film, #n ◦ salle, #n ◦ créneau, tarif)

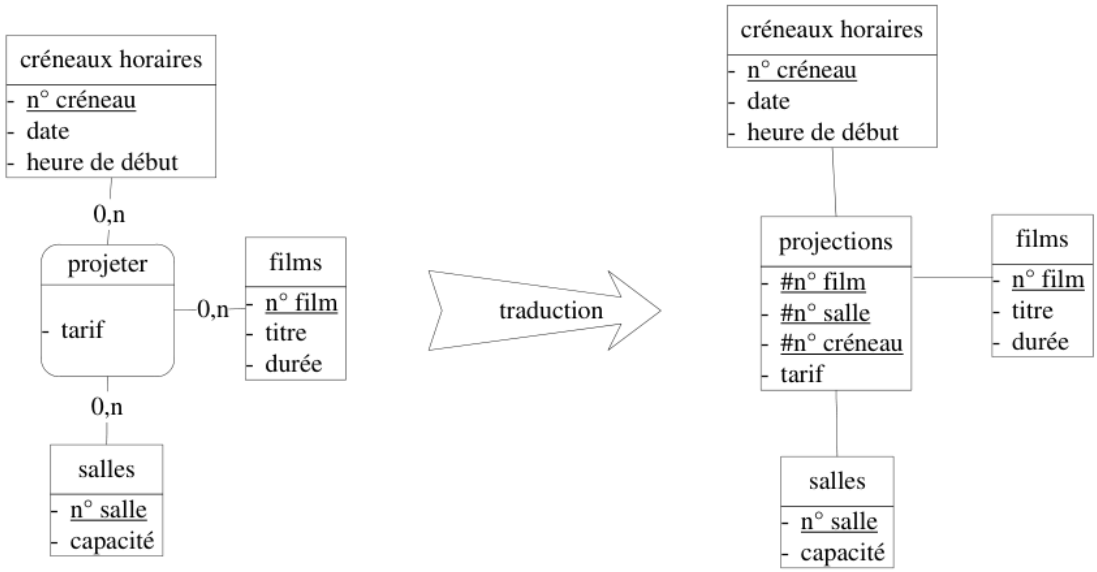


Fig. 31 – Traduction d'une association ternaire

3 Modèle physique de données (MPD)

Un modèle physique de données est l'implémentation particulière du modèle logique de données par un logiciel.

3.1 Distinction entre MLD et MPD

La traduction d'un MLD conduit à un MPD qui précise notamment le stockage de chaque donnée à travers son type et sa taille (en octets ou en bits). Cette traduction est également l'occasion d'un certain nombre de libertés prises par rapport aux règles de normalisation afin d'optimiser les performances du système d'information.

La traduction d'un MLD relationnel en un modèle physique est la création (par des requêtes SQL de type CREATE TABLE et ADD CONSTRAINT) d'une base de données hébergée par un SGBD relationnel particulier. Il peut s'agir d'une base Oracle, d'une base SQL Server, d'une base Access ou d'une base DB2, par exemple. Le fait que tous les SGBDR reposent sur le même modèle logique (le schéma relationnel) permet à la fois la communication entre des bases hétérogènes et la conversion d'une base de données d'une SGBDR à l'autre.

3.2 Optimisations

L'optimisation des performances en temps de calcul se fait toujours au détriment de l'espace

mémoire consommé. Dans le pire des cas, réduire les temps de réponse consiste à dénormaliser volontairement le système d'information, avec tous les risques d'incohérence et les problèmes de gestion que cela comporte.

Pour les bases de données relationnelles, l'optimisation qui vise à accélérer les requêtes peut passer par : – l'ajout d'index aux tables (au minimum sur les colonnes clés primaires et clés étrangères) ; ces index consomment de l'espace mémoire supplémentaire, mais la base de données reste normalisée ; – l'ajout de colonnes calculées ou de certaines redondances pour éviter des jointures coûteuses (auquel cas la base est dénormalisée) ; il faut alors veiller à ce que la cohérence entre les colonnes soit respectée, soit par l'utilisation de déclencheurs, soit dans les applications clientes du système d'information ; – la suppression des contraintes d'unicité, de non vacuité ou encore de clé étrangère (auquel cas, l'intégrité des données doit être assurée par le code client du système d'information).

Par exemple, la table commandes de la figure 28 peut être supprimée et la date de commande est alors ajoutée à la table lignes de commandes. On renonce donc à la troisième forme normale (figure 32)

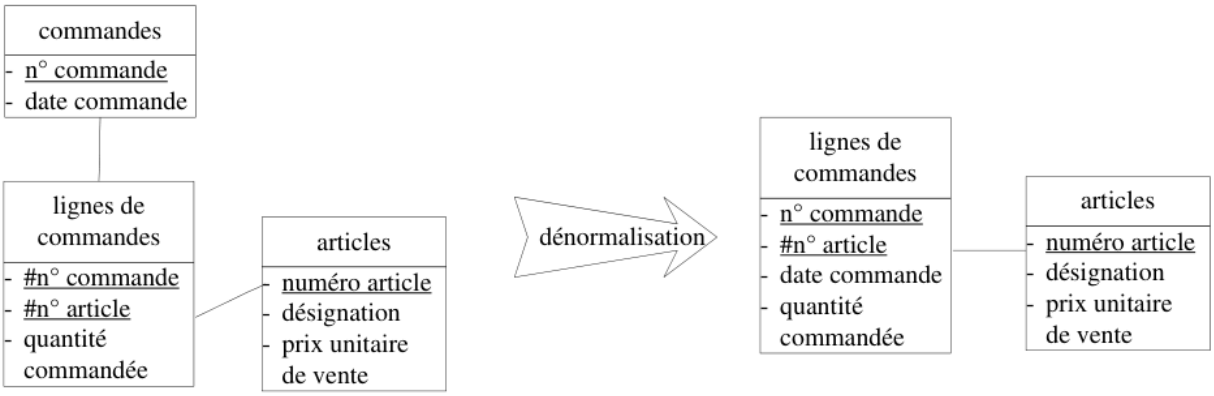


Fig. 32 – Sacrifice de la troisième forme normale